



基于光照不变正则约束的稳健性 桥梁病害识别

刘新龙¹, 邓磊¹, 杨建喜¹, 田丽萍²

(1. 重庆交通大学 信息科学与工程学院, 重庆 400074;
2. 中国交通信息科技集团有限公司, 北京 100088)

摘要: 桥梁表观病害识别是桥梁运营养护的关键技术之一。近年来, 卷积神经网络(Convolutional Neural Networks, CNN)被广泛应用于桥梁表观病害识别。然而在光照不足条件下, 卷积神经网络对于桥梁表观病害识别的稳健性通常不足。针对上述问题, 提出一种基于光照不变正则约束的稳健性桥梁病害识别方法。该方法利用不变正则约束, 同时约束CNN的特征提取模块和分类器模块, 实现光照不足条件下的不变特征学习和分类器学习, 进而增强CNN模型对于桥梁病害识别的光照稳健性。运用该方法基于桥梁表观病害数据集进行实验验证。实验结果表明: 所提方法在光照不足条件下的桥梁病害的平均识别准确率高于对比方法; 该方法在正常光照图像和光照变化图像上提取的特征矢量的欧氏距离为 7.57, 较对比方法提取的特征矢量具有更高的相似度。基于光照不变正则约束的稳健性桥梁病害识别方法在光照不足条件下提取的特征具有较强的不变特性, 使得模型具有较强的病害识别稳健性, 具有良好的工程应用价值, 能够为桥梁的运营养护提供更准确的决策支持。

关键词: 桥梁表观病害识别; 卷积神经网络; 光照稳健性; 正则约束; 特征学习

中图分类号: U446; TP391.41

文献标志码: A

开放科学(资源服务)标识码(OSID)

文章编号: 1672-7029 (2023) 07-2728-12



Illumination-invariance approach based on invariant regularization for bridge disease identification

LIU Xinlong¹, DENG Lei¹, YANG Jianxi¹, TIAN Liping²

(1. School of Information Science and Engineering, Chongqing Jiaotong University, Chongqing 400074, China;

2. China Communication Information Technology Group Co., Ltd., Beijing 100088, China)

Abstract: Bridge surface disease identification is one of the key technologies of bridge operation and maintenance. In recent years, Convolutional Neural Networks (CNN) has been widely used in the identification of bridge surface disease. However, the robustness of CNN model for bridge surface disease identification is usually insufficient under the condition of insufficient illumination. To address this problem, an illumination-invariance approach based on invariant regularization for robust bridge disease identification was proposed in this paper. In the proposed method, to achieve robust bridge disease identification to illumination, the invariant

收稿日期: 2022-07-07

基金项目: 重庆市教委科学技术研究资助项目(KJQN202100748, KJZD-M202000702); 重庆交通大学校内科学基金资助项目(20JDKC-B038)

通信作者: 杨建喜(1977—), 男, 宁夏青铜峡人, 教授, 博士, 从事桥梁健康监测研究; E-mail: yjx@cqjtu.edu.cn

regularity constraint was used to constrain both the feature extraction module and classification module of CNN for invariant feature learning and classifier learning, and then enhance the illumination robustness of CNN model for bridge disease recognition, respectively. The proposed method was applied to the experimental verification based on the bridge surface diseases dataset. The results show that the average identification accuracy of the proposed method for bridge diseases under insufficient illumination is higher than that of the comparison method. The Euclidean distance of the feature vector extracted by this method on the normal illumination image and the illumination change image is 7.57, which has a higher similarity than the feature vector extracted by the contrast method. The features extracted by an illumination-invariance approach based on invariant regularization for robust bridge disease identification under the condition of insufficient illumination have strong invariance, which makes the proposed model have strong robustness of disease identification, has good engineering application value, and can provide more accurate decision support for the operation and maintenance of bridges.

Key words: bridge surface disease identification; convolutional neural network; robustness to illumination; regularization constraint; feature learning

受混凝土老化、车辆超载、运营环境恶化等多重因素耦合作用,桥梁结构在长期服役过程中会不可避免地产生裂缝、剥落、露筋等病害^[1],准确识别桥梁病害类型对于桥梁结构状态评估至关重要。传统基于人工的桥梁病害识别方法不仅存在着主观性强以及效率低等问题,而且在实施桥梁病害识别过程中需要封闭道路。因此,传统识别方法逐渐无法适应实际应用场景。随着深度学习技术的发展^[2-4],基于深度学习的桥梁病害识别方法逐渐成为当前研究的重点^[5-6]。该类方法不仅自动化程度高,而且具有较高的识别准确率。近年来,基于卷积神经网络(Convolutional Neural Networks, CNN)的方法逐渐用于智能化的桥梁病害识别^[7]。ZHANG等^[8]提出一种基于CNN的裂缝识别方法,该方法将深度学习用于裂缝识别,相比于传统基于支持向量机(Support Vector Machine, SVM)和Boosting等方法,该方法具有更高的裂缝识别性能。CHA等^[9]提出基于CNN的混凝土裂缝识别方法,相比于Canny和Sobel等方法,该方法可实现自动特征提取,且在复杂背景下具有较高的识别准确率和鲁棒性。沙爱民等^[10]将CNN用于道路病害识别,该方法通过自动特征提取,实现了裂缝和坑槽病害的识别,提高了病害识别的速度。王桂平等^[11]提出一种基于迁移学习的桥梁表观病害检测方法,该方法通过迁移学习有效地缓解了因训练样本不足而引起的模型过拟合问题,实

现了泛碱、漏筋和裂缝等病害的准确识别。晏班夫等^[12]提出一种基于CNN和形态学的集成识别方法,该方法基于Faster R-CNN对病害进行检测,实现了裂缝形态的准确提取,不仅具有裂缝的长度与宽度识别能力,而且有效降低了病害检测的误检率。邹俊志等^[13]提出了一种基于YOLO-v3的桥梁病害检测方法,该方法通过注意力机制和空间金字塔模块,有效抑制了复杂场景下桥梁表面背景信息,实现了高速且精准的桥梁病害识别。上述方法在复杂场景下仍然存在错误识别桥梁病害的情况,且其病害识别的光照稳健性尚有待提高。然而,在光照不足条件下,基于CNN的方法对于桥梁病害识别的稳健性尚存在不足^[14]。为了解决该问题,学者们提出了许多有效的方法,该类方法可分为基于光照归一化的方法、基于光照建模的方法和基于光照不变特征提取的方法。1)基于光照归一化的方法在给定的光照水平下归一化图像的整体强度,可有效降低光照变化的影响;常用的归一化方法如直方图均衡^[15]、伽马校正^[16]和对数变换^[17]等。2)基于光照建模的方法构建不同光照条件下图像的低维光照子空间,并在子空间内合成图像,典型的子空间构建方法如线性子空间方法^[18]以及光锥法^[19]等。3)基于光照不变特征提取的方法,通过提取对于光照变化稳健的特征,从而减小光照变化对识别性能的影响。袁小平等^[20]提出一种改进Gabor特征的自商图算法,该方法通

过加权 Gabor 滤波器提取光照变化稳健的特征，消除了光照变化对识别任务的影响，有效地提高了识别性能与光照鲁棒性。蔡道清等^[2]提出一种基于小波变换的光照不变特征提取算法，该方法采用小波变换和阈值法提取光照不变特征，增强了特征提取在光照变化条件下的鲁棒性。上述方法基于手工特征，其特征表示能力和识别性能尚不足，且为了顾及识别性能和光照稳健性需要进行手工阈值设置。基于光照归一化的方法在复杂光照条件下的病害识别准确率不佳，基于光照建模的方法需要大量不同光照条件下的图像构建子空间，基于光照不变特征提取的方法的稳健性仍然存在

不足。因此，研究光照不足条件下基于 CNN 的桥梁病害识别方法的稳健性具有重要意义。针对上述光照稳健性问题，本文提出一种基于光照不变正则约束的稳健性桥梁病害识别方法，其原理如图 1 所示。图中， $\mathcal{L}_{\text{distance}}(\psi(x), \psi(x'))$ 表示特征距离损失函数， $\mathcal{L}_{\text{clean}}(x, y)$ 和 $\mathcal{L}_{\text{change}}(x', y)$ 分别表示正常光照和光照变化时的分类损失函数。该方法通过同时最小化特征距离损失函数和分类损失函数，实现光照不足条件下的光照不变特征学习与分类器学习，进而增强 CNN 模型对于桥梁病害识别的光照稳健性。



图 1 基于光照不变正则约束的桥梁病害稳健识别方法原理示意图

Fig. 1 Framework of illumination-invariance approach based on invariant regularization for bridge disease identification

1 本文方法

1.1 问题描述

基于 CNN 模型的桥梁病害识别网络结构可划分为两大功能模块，分别为特征提取模块和分类器模块，如图 2 所示。对于桥梁病害图像的类型识别，CNN 模型首先通过特征提取模块提取桥梁病害图像的特征，然后通过分类器模块将提取到的特征映射到具体的桥梁病害类型。具体来讲，记桥梁病害图像为 x ，其对应的标签为 y ；则经 CNN 特征提取模块后的特征描述可表示为 $\psi(x)$ ，特征 $\psi(x)$ 经分类器模块后的输出可表示为 \hat{y} 。为了实现准确的桥梁病害识别任务，CNN 的分类器预测结果 \hat{y} 应该与输入 x 的原始标签 y 保持一致。

光照变化对于 CNN 模型的影响不仅体现在改变其分类器预测结果，而且影响其特征提取模块的输出。记桥梁病害图像 x 在光照变化条件下其对应的图像为 x' ，则 x' 经 CNN 特征提取模块和分类器模块输出可分别记为 $\psi(x')$ 和 \hat{y}' 。那么，为了使 CNN 模型在光照变化条件下具有桥梁病害识别的稳健性，应从以下 2 个方面考虑：1) 从特征提取角度分析，特征描述 $\psi(x')$ 与 $\psi(x)$ 应具有相似性，即光照变化并未引起特征矢量的变化，则分类器的预测结果越趋于一致。2) 从分类器角度分析，若特征描述 $\psi(x')$ 与 $\psi(x)$ 之间存在变化性，则应优化分类器参数，使得其对于 $\psi(x')$ 与 $\psi(x)$ 具有相同的预测结果，即预测结果 \hat{y}' 应该与 \hat{y} 保持一致。因此，CNN 模型对于光照变化的稳健性，应该同时

考虑其特征提取模块和分类器模块的光照不变性。

本文提出一种基于光照不变正则约束的稳健性桥梁病害识别方法。该方法同时约束CNN的特

征提取模块和分类器模块, 实现光照变化条件下的不变特征学习与分类器学习, 进而增强CNN模型对于桥梁病害识别的光照稳健性。

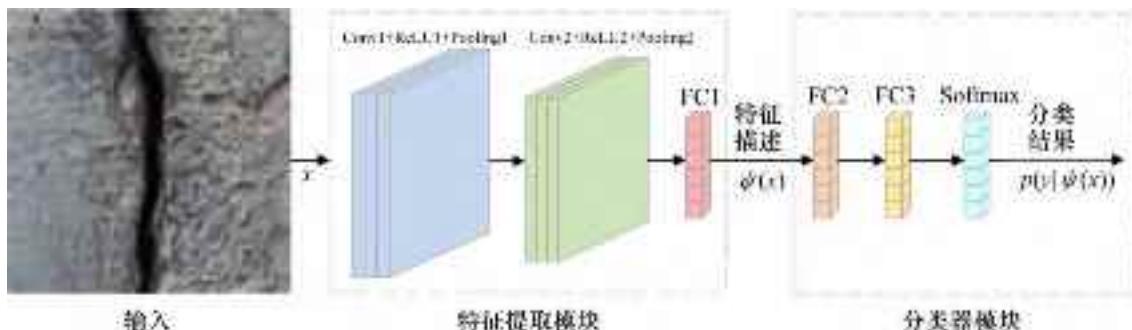


图2 面向桥梁病害识别的CNN功能模块划分

Fig. 2 Functional module of CNN for bridge disease identification

1.2 方法原理

本文为研究桥梁病害识别与光照变化的关系, 在单路卷积神经网络的基础上设计一个对称的并行同步卷积神经网络, 同时添加权值共享与正则约束构成光照不变卷积神经网络模型(Illumination-Invariance Convolutional Neural Networks, IICNN)。该模型通过光照不变的特征学习与分类器学习, 实现光照变化条件下的稳健性桥梁病害识别。其中, 光照不变的特征学习指的是在特征提取模块权值共享的情况下, 约束正常光照病害图像与其对应光照变化病害图像的特征矢量欧式距离最小; 光照不变的分类器学习指的是在分类器模块权值共享的情况下, 约束正常光照病害图像与光照变化病害图像的分类标签相同。需要注意的是, 本文提出的IICNN模型是个通用模型, 可以适用于不同的CNN结构中。

1.3 网络结构

本文IICNN模型同时考虑特征提取模块和分类器模块, 并基于正则化参数优化方式约束特征矢量与分类结果的光照不变性, 在光照变化条件下提升模型对于桥梁病害识别的稳健性。以下分别介绍面向特征提取模块和分类器模块的光照不变约束原理。

1.3.1 特征提取模块

特征提取模块主要由卷积层、激活层、池化层以及全连接层构成, 如图2所示。特征提取模块将输入图像从图像空间映射到特征空间, 对于正常光照图像输入 x 与其对应光照变化扩展图像 x' ,

经特征提取后的特征矢量可分别记为 $\psi(x)$ 和 $\psi(x')$ 。

由于光照变化会显著改变桥梁病害中的特征, 因此引入光照不变的特征约束, 使得光照变化图像的特征能够更接近正常光照图像的特征。从特征提取角度讲, 本文引入光照不变的特征约束, 使得约束后的特征矢量 $\psi(x')$ 与 $\psi(x)$ 趋于一致, 最大限度地减少从正常光照图像与光照变化图像中获得的特征之间的差异, 即光照变化不能造成特征矢量的强变异性。

1.3.2 分类器模块

分类器模块主要由2个全连接层和Softmax层构成, 如图2所示。分类器模块基于上述特征矢量 $\psi(x)$ 和 $\psi(x')$ 得到的分类概率可分别记为 $p(y|\psi(x))$ 和 $p(y'|\psi(x'))$, 其中 y 和 y' 分别表示 x 和 x' 的分类标签。由于光照变化图像 x' 是正常光照图像 x 的扩展数据, 为了实现光照变化条件下的稳健性桥梁病害识别, 故它们的标签应相同, 即 $y'=y$, 所以 $p(y'|\psi(x')) \approx p(y|\psi(x))$ 。

由于光照变化会显著降低桥梁病害的分类精度, 因此引入光照不变的分类器约束, 满足分类器对于光照变化图像 x' 的分类概率 $p(y'|\psi(x'))$ 与正常光照图像的分类概率 $p(y|\psi(x))$ 尽可能相近。从分类器角度讲, 本文引入光照不变的分类器约束, 使得优化后的分类器对 $\psi(x')$ 和 $\psi(x)$ 的分类结果趋于一致, 即减小光照变化对分类结果的影响。

1.4 约束优化

为实现光照不变的特征学习与分类器学习,

在模型优化函数中引入光照不变的特征约束和分类器约束。具体来讲，记训练数据集为 $\mathcal{D}\{\langle \mathbf{x}_n, \mathbf{x}_n^\gamma; y_n \rangle\}_{n=1}^N$ ，其中 \mathbf{x}_n 表示第 n 个正常光照训练样本， \mathbf{x}_n^γ 表示采用式(5)表示的Gamma校正模型对 \mathbf{x}_n 合成参数为 γ 的光照变化样本， y_n 为 \mathbf{x}_n 的标签， N 为训练样本个数。整体损失函数可以表示为：

$$\begin{aligned} \mathcal{L} &= \mathcal{L}_{\text{clean}}(\mathbf{x}_n, y_n) + \mathcal{L}_{\text{change}}(\mathbf{x}_n^\gamma, y_n) + \lambda \cdot \\ &\quad \mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma)) \end{aligned} \quad (1)$$

式中： $\mathcal{L}_{\text{clean}}(\mathbf{x}_n, y_n)$ 和 $\mathcal{L}_{\text{change}}(\mathbf{x}_n^\gamma, y_n)$ 分别表示正常光照图像 \mathbf{x}_n 和光照变化图像 \mathbf{x}_n^γ 在IICNN模型中的分类损失函数。 $\mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma))$ 表示正常光照图像 \mathbf{x}_n 和光照变化图像 \mathbf{x}_n^γ 的特征矢量 $\psi(\mathbf{x}_n)$ 和 $\psi(\mathbf{x}_n^\gamma)$ 之间的距离损失函数， λ 为正则项超参数，用于控制距离约束代价函数 $\mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma))$ 在整体损失函数中的参与度。以下分别介绍距离损失函数和分类损失函数。

1.4.1 距离损失函数

光照变化对图像所造成的改变会引起特征提取模块输出的变化，造成分类器模块的错误类别预测。为了解决该问题，引入距离损失函数 $\mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma))$ 约束光照变化图像 \mathbf{x}_n^γ 的特征矢量 $\psi(\mathbf{x}_n^\gamma)$ 尽可能接近正常光照图像 \mathbf{x}_n 的特征矢量 $\psi(\mathbf{x}_n)$ 。距离损失函数 $\mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma))$ 的定义如下：

$$\mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma)) = \|\psi(\mathbf{x}_n) - \psi(\mathbf{x}_n^\gamma)\|_2^2 \quad (2)$$

式中： $\|\cdot\|_2^2$ 表示 l_2 范数的平方。距离损失函数 $\mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma))$ 本质上是一种基于欧式距离的矢量相似性度量，最小化损失函数 $\mathcal{L}_{\text{distance}}(\psi(\mathbf{x}_n), \psi(\mathbf{x}_n^\gamma))$ 等价于欧式空间内矢量 $\psi(\mathbf{x}_n)$ 与 $\psi(\mathbf{x}_n^\gamma)$ 越相似。

1.4.2 分类损失函数

本文IICNN模型对于光照变化的稳健性体现在其分类结果不受光照变化的影响，故光照变化图像与对应光照正常图像的分类结果应该相同，但光照变化对图像造成的改变会导致不同的分类结果。为了解决该问题，引入正常光照图像 \mathbf{x}_n 和光照变化图像 \mathbf{x}_n^γ 经IICNN模型的分类损失函数 $\mathcal{L}_{\text{clean}}(\mathbf{x}_n, y_n)$ 和 $\mathcal{L}_{\text{change}}(\mathbf{x}_n^\gamma, y_n)$ ，约束正常光照图像 \mathbf{x}_n 与其对应光照变化图像 \mathbf{x}_n^γ 的分类结果一致。对于

多分类问题，分类损失函数采用交叉熵损失函数^[22]， $\mathcal{L}_{\text{clean}}(\mathbf{x}_n, y_n)$ 和 $\mathcal{L}_{\text{change}}(\mathbf{x}_n^\gamma, y_n)$ 的定义如下：

$$\mathcal{L}_{\text{clean}}(\mathbf{x}_n, y_n) = -\ln p(\mathbf{x}_n, y_n) \quad (3)$$

$$\mathcal{L}_{\text{change}}(\mathbf{x}_n^\gamma, y_n) = -\ln p(\mathbf{x}_n^\gamma, y_n) \quad (4)$$

式中： $p(\mathbf{x}_n^\gamma)$ 表示Softmax层输出的预测概率矢量， y_n 表示标签 y_n 基于One-Hot编码^[23]的标签矢量。

本文损失函数通过约束正常光照图像与光照变化图像的特征差异性，以降低特征对光照的敏感性，即：减小由光照变化所引起的特征提取模块输出变化和分类器模块识别结果变化，从而实现对正常光照图像与光照变化图像的准确识别，提升模型对于光照变化的稳健性。

2 实验与分析

2.1 实验数据

由于目前没有公开的桥梁病害数据集，故需要人工采集病害图像以构建数据集。本文整理了重庆、四川等地1280份桥梁检测报告，采集了大量病害图像，并针对裂缝、剥落、露筋、渗水、背景5种主要类别构建实验数据集。针对采集的大量病害图像，采用基于滑动窗口的病害图像人工扩增方法^[24]构建数据集。由于 64×64 的子图更能绘出更贴合的病害形态轮廓，将原始图像通过滑动窗口的人工数据扩增为 64×64 的病害图像，其中每种类别2500张，总计12500张。为进一步扩充数据，采取水平、竖直翻转以及旋转的方法，对原始图像进行处理，使数据扩充到原来的6倍，总计为75000张。

为了便于分析与讨论光照变化对CNN性能的影响，以及验证本文IICNN模型的光照稳健性，需要在原始数据集的基础上扩充一个光照变化数据集，故本文采用Gamma校正合成数据的方式对图像进行光照强度变化。Gamma校正^[25]通过增强图像像素值偏低部分的对比度改变图像整体亮度，能够更好地模拟实验所需的光照强度变化。Gamma校正函数可表示为^[25]：

$$I_{\text{out}} = c I_{\text{in}}^\gamma \quad (5)$$

式中： I_{out} 表示输出图像中的灰度值， c 为常数， I_{in} 表示输入图像中的灰度值。 γ 为自定义参数，决定

Gamma校正对灰度值的改变程度。如图3所示, 当 $\gamma=1$ 时, Gamma校正不改变图像的灰度值; 当 $0<\gamma<1$ 时, Gamma校正使图像的灰度值增大, 输出图像变亮; 当 $\gamma>1$ 时, Gamma校正使图像的灰度值减小, 输出图像变暗。

本文将数据集的60%作为训练集, 20%作为验证集。将剩余的20%图像采用式(5)表示的Gamma校正模型合成不同光照强度下的测试图像, γ 从1取到3, 每次的增量值为0.1, 将每张图像扩充到30张光照强度不同的图像。进一步对Gamma校正后的图像加入均值为1, 方差为0.03的高斯噪声模拟真实场景下的光照变化。图4给出了Gamma校正改变光照示意图, 第1行为Gamma校正后的图像, 从左到右 γ 由1到3逐渐增大, 图像逐渐变暗。第2行为对应Gamma校正图像加入高斯噪声后的

图像。

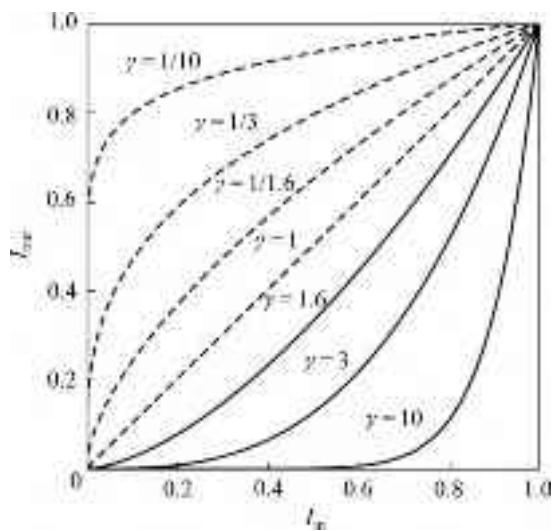


图3 Gamma校正示意图

Fig. 3 Gamma correction diagram



图4 Gamma校正改变光照

Fig. 4 Gamma correction change illumination

2.2 实验设置

本文实验中的单路卷积神经网络使用LeNet^[2]网络, 其参数设置如表1所示。其中, Conv表示卷积层, Pooling表示池化层, FC表示全连接层。

实验基于Pytorch1.7.0深度学习框架完成, 操作系统为Ubuntu Linux 18.04, 在CPU环境(Intel(R) Xeon(R) Gold 6226R CPU @2.90 GHZ)和GPU环境(NVIDIA GeForce RTX 3090)下进行训练。实验中batch size大小设置为512, 训练次数epoch设置为100轮。网络使用SGD优化器, 网络初始学习率设置为0.01, 动量设置为0.9。为提高模型计算速度, 数据集所有图像均被缩放至32×32大小。为了验证本文方法有效性, 对比方法包括基于数据增强的方法和基于噪声不变特征约束的方法。3

种实验方法的设置如下。

表1 CNN结构

Table 1 Structure of CNN

层名	参数设置	通道个数
Conv1	卷积核:5×5;步长:1;激活函数:ReLU	16
Pooling1	池化层:2×2;步长:2;Max Pooling	16
Conv2	卷积核:5×5;步长:1;激活函数:ReLU	32
Pooling3	池化层:2×2;步长:2;Max Pooling	32
FC1	神经元个数:120	—
FC2	神经元个数:84	—
FC3	神经元个数:5	—

基于数据增强的方法(Data Augmentation, DA)^[26]: 在正常光照数据集上进行光照变化扩展处

理，并将正常光照数据集与光照变化图像数据集合并后输入表1所示的单路CNN模型进行训练。

基于噪声不变特征约束的方法(Speckle Noise Invariant Convolutional Neural Network, SNICNN)^[27]: 设置模型特征提取部分权值共享与特征不变正则约束，具体实现如图5所示。SNICNN模型通过权值共享与特征不变正则约束，减小正常光照图像与其对应光照变化图像的特征差异性。具体来讲，将正常光照图像与其对应的光照变化图像输入进2个相互对应的特征提取模块进行特征提取，并设置该特征提取模块对应的卷积层参数共享以及对其特征提取模块引入约束。需要注意的是同时输

入网络的是正常光照图像与其对应的光照变化图像。

基于光照不变正则约束的稳健性桥梁病害识别方法(IICNN): 设置模型的特征提取部分和分类器部分权值共享，并引入特征不变与分类不变约束，具体实现如图6所示。IICNN模型通过权值共享与特征不变、分类不变正则约束，以实现光照不变的特征学习与分类器学习。具体来讲，与SNICNN模型的实现方式类似，其约束通过权值共享和正则化约束上实现。不同的是，在图6所示的2个子网络中，对应的全连接层FC2和FC3层权值共享，且对应的Softmax层用于计算预测的标签共享。

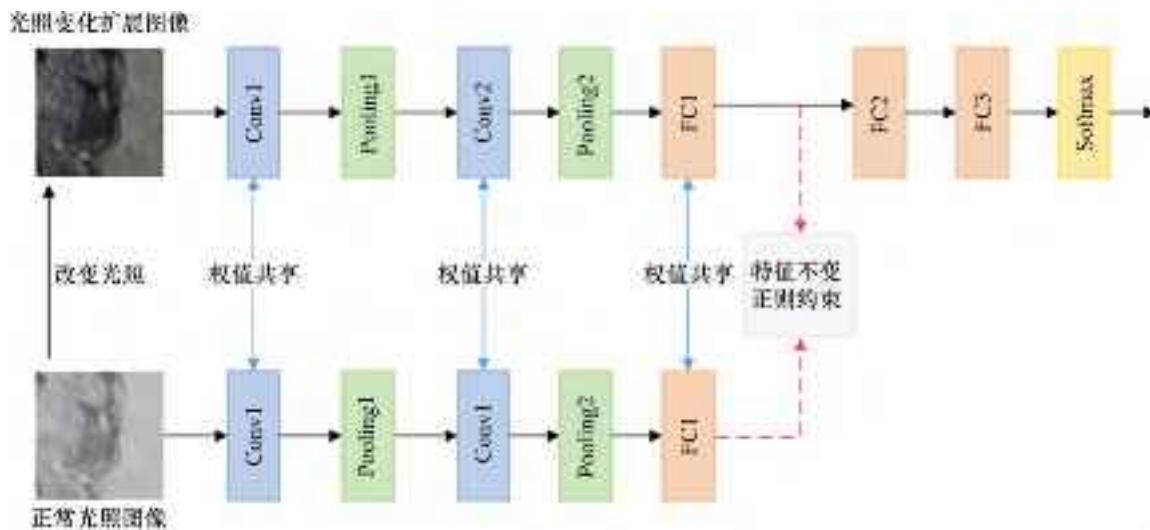


图5 SNICNN模型实现示意图

Fig. 5 Implementation diagram of SNICNN model

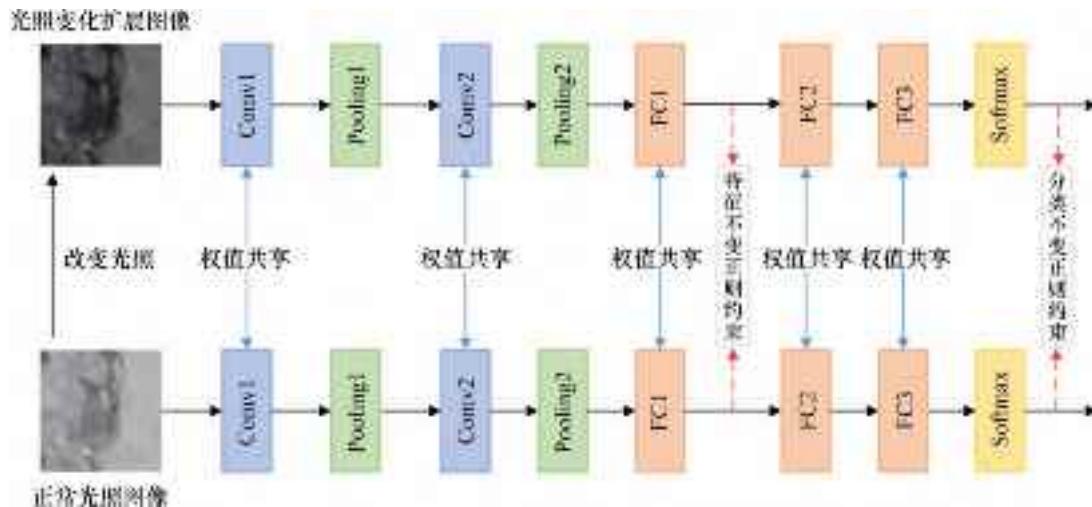


图6 IICNN模型实现示意图

Fig. 6 Implementation diagram of IICNN Model

2.3 实验结果

以下分别给出光照变化对 CNN 模型识别性能的影响分析、IICNN 模型的光照稳健性分析和特征相似性分析的实验结果。

2.3.1 光照变化对 CNN 模型识别性能的影响分析

为了验证 CNN 模型在光照变化条件下的识别有效性, 将数据集输入表 1 所示的 CNN 模型中, 利用识别准确率定量评价不同光照强度下 CNN 模型的性能。在扩展的光照变化测试集上的实验结果如图 7 所示。考虑到添加高斯噪声的随机性, 图中给出了 10 次实验结果, 图中虚线表示正常光照时的参考准确率, 实线表示不同光照强度下的平

均准确率。

图 7 中的实验结果表明: 光照变化对于 CNN 模型的性能影响显著。具体来讲, 当光照略微不足时, CNN 模型的性能略有下降; 例如, 当 $\gamma=1.5$ 时, 在光照变化测试数据上的平均识别准确率约为 74.25%, 低于正常光照时的平均准确率。当光照严重不足时, CNN 模型平均识别准确率极低; 例如, 当 $\gamma=3$ 时, 在光照变化测试数据上的平均识别准确率约为 34.60%。上述实验表明: 光照变化对于 CNN 模型的性能具有重要影响, 特别是在光照严重不足时, CNN 模型的识别准确率极低, 接近于随机猜测。

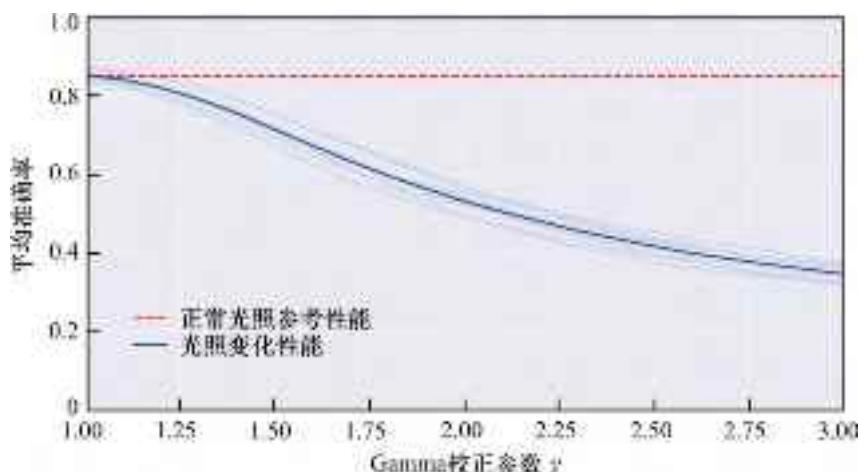


图 7 光照变化对 CNN 模型平均识别准确率的影响

Fig. 7 Influence of illumination change on average classification accuracy of CNN model

2.3.2 IICNN 模型的光照稳健性分析

为了分析 IICNN 模型识别性能对于光照变化的稳健性, 在相同训练设置下以 DA 和 SNICNN 模型为参考, 利用识别准确率评价不同光照强度下对比方法的性能。首先, 将原有的训练集与验证集利用式(5)合成的光照变化图像, 再将 2 张相对应图像分别输入并行的卷积神经网络中。然后, 在扩展的光照变化测试集上分析不同光照强度对上述网络模型性能的影响。考虑到添加高斯噪声的随机性, 实验采用多次实现与取平均的方式分析识别准确率。图 8 给出了实验结果, 图中虚线表示正常光照时的参考准确率, 加粗实线表示多次实验结果的平均值; 例如: 虚线下的加粗实线表示 IICNN 模型 10 次实验结果的平均准确率。

图 8 中的实验结果表明: IICNN 模型的光照稳

健性优于 DA 和 SNICNN 模型。具体来讲, 当 $\gamma=2.5$ 时, DA 在光照变化测试数据上的平均识别准确率约为 49.28%, 远低于对于模型在正常光照时的平均识别准确率 85.05%; SNICNN 在光照变化测试数据上的平均识别准确率相比于 DA 有明显提升, 约为 54.97%, 但仍然低于正常光照条件下的参考值; IICNN 在光照变化测试数据上的平均识别准确率高于 DA 和 SNICNN, 其准确率约为 74.05%, 说明其光照稳健性相对较好。当 γ 取其他值时, DA 的平均准确率远低于参考值, 说明该模型的光照稳健性相对较弱; SNICNN 的平均准确率高于 DA, 表明该模型的光照稳健性强于 DA; IICNN 模型的平均识别准确率高于 DA 和 SNICNN, 表明其光照稳健性优于 DA 和 SNICNN。上述实验表明: IICNN 模型具有相对较强的光照稳健性。需

指出的是 IICNN 模型在光照严重不足时的平均准确率仍有下降的趋势，这是因为模型训练时仅采用了参数 $\gamma=1.6$ 的光照变化图像。为防止上述性能下降，可通过扩展其他 γ 参数下的训练数据并用于模型训练。

2.3.3 特征相似性分析

为了进一步验证 IICNN 模型具有光照不变性，在相同训练设置下以 DA 和 SNICNN 模型为参考，通过比较正常光照图像与其对应的光照变化图像经 IICNN 模型提取到的特征矢量在欧式空间的相似性，比较各个模型的光照不变性。首先，随机

选取正常光照的测试图像，利用式(5)将其合成不同光照强度下的光照变化图像。然后，将 2 张相对应图像输入实验 2 训练好的模型中，比较各个模型输出特征矢量的相似性。其中特征矢量的相似性以欧氏距离度量，欧式距离越小，特征矢量越相似。

图 9 展示了用于特征相似性比较的样本图像，图 9(a) 为正常光照图像，图 9(b) 为其对应的光照变化图像，其 Gamma 校正 $\gamma=2.5$ 。图 10 为样本图像经 DA, SNICNN 和 IICNN 模型提取的特征相似性实验结果。

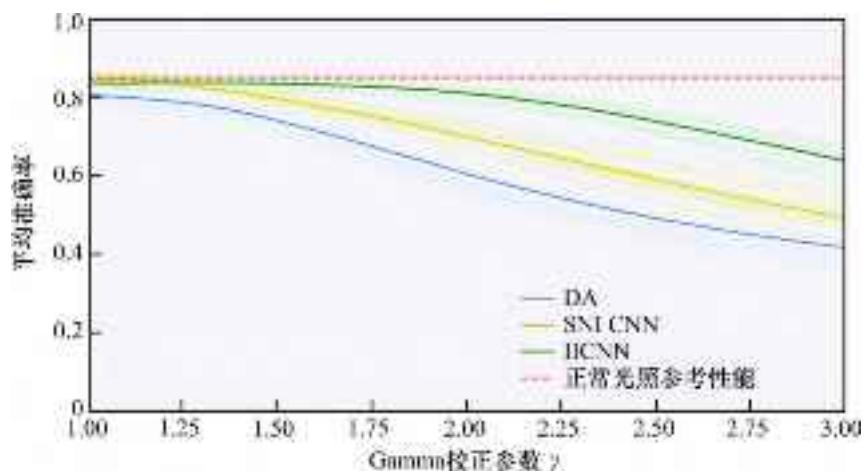
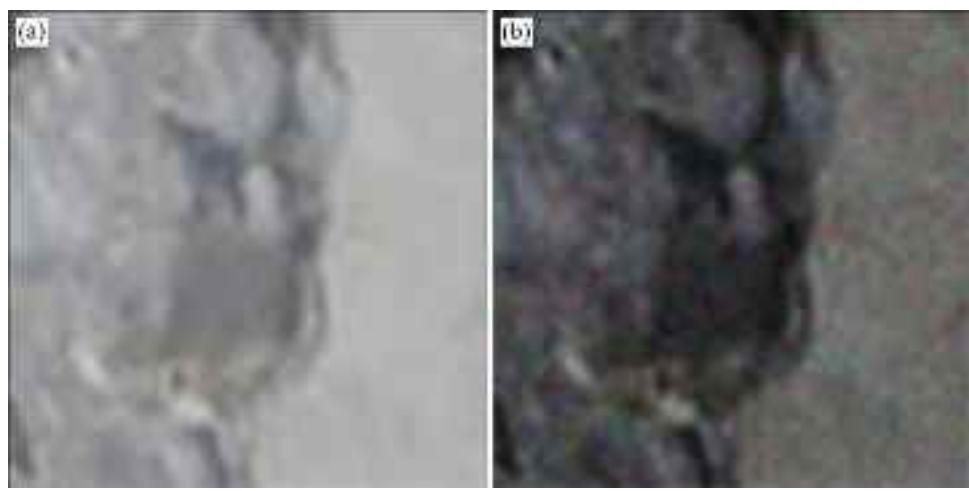


图 8 IICNN 模型的光照稳健性分析

Fig. 8 Robustness analysis of IICNN model to illumination change



(a) 正常光照图像; (b) 光照变化图像

图 9 样本图像

Fig. 9 Sample image

图 10 中的实验结果表明，相比于 2 种对比方法，本文提出的 IICNN 模型在正常光照图像和光

照变化图像上提取的特征矢量具有较高的相似度。具体来讲，本文 IICNN 模型在样本图像上的欧式

距离为 7.57, 该距离略小于基于 SNICNN 的欧式距离 21.41, 该距离也远小于基于 DA 的欧式距离 210.22。此外, 上述实验也表明基于本文 IICNN 模型的图像特征矢量稀疏性更高。

上述实验表明: IICNN 模型提取的特征矢量具有相对较强的光照不变性。

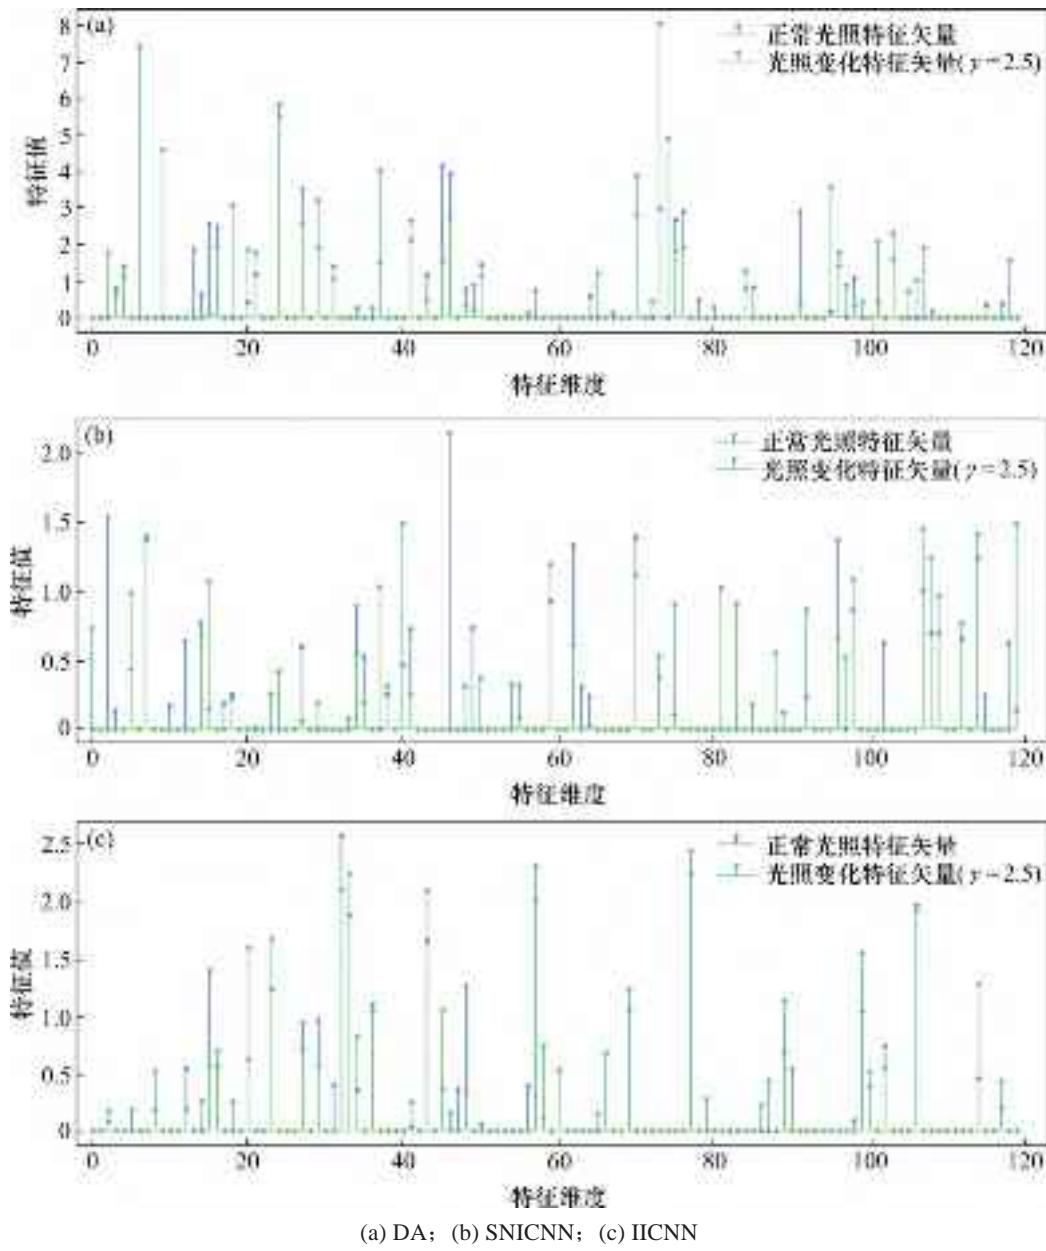


图 10 样本图像特征相似性比较

Fig. 10 Feature similarity comparison of sample images

3 结论

1) 针对光照变化条件下卷积神经网络对于桥梁病害识别的稳健性问题, 提出一种基于光照不变正则约束的稳健性桥梁病害识别方法。该方法通过光照不变正则约束, 实现了对于光照不变的特征学习与分类器学习, 从而增强了光照不足条

件下卷积神经网络对于桥梁病害识别的稳健性。

2) 基于实测数据验证了本文方法在光照不足情况下具有特征不变性和分类不变性。本文方法能够准确提取光照不足条件下的桥梁表观病害特征, 可用于在役桥梁表观病害识别, 具有良好的工程应用价值。

3) 在未来工作中, 基于本文方法面向光照过

强条件下的桥梁病害识别稳健性将是一个值得探索的研究。

参考文献:

- [1] 贺拴海,赵祥模,马建,等.公路桥梁检测及评价技术综述[J].中国公路学报,2017,30(11): 63–80.
HE Shuanhai, ZHAO Xiangmo, MA Jian, et al. Review of highway bridge inspection and condition assessment [J]. China Journal of Highway and Transport, 2017, 30(11): 63–80.
- [2] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436–444.
- [3] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition [EB/OL]. 2014: arXiv: 1409.1556. <https://arxiv.org/abs/1409.1556>.
- [4] HE Kaiming, ZHANG Xiangyu, REN Shaoqing, et al. Deep residual learning for image recognition[C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). June 27-30, 2016, Las Vegas, NV, USA. IEEE, 2016: 770–778.
- [5] 杨杰文,章光,陈西江,等.基于深度学习的较复杂背景下桥梁裂缝检测[J].铁道科学与工程学报,2020,17(11): 2722–2728.
YANG Jiewen, ZHANG Guang, CHEN Xijiang, et al. Research on bridge crack detection based on deep learning under complex background[J]. Journal of Railway Science and Engineering, 2020, 17(11): 2722 – 2728.
- [6] 哈纳提·吐尔森哈力,林杭.融合自注意力机制与深度学习的混凝土表面裂隙智能识别[J].铁道科学与工程学报,2021,18(4): 844–852.
HANAT Tursenali, LIN Hang. Intelligent identification of cracks on concrete surface combining self-attention mechanism and deep learning[J]. Journal of Railway Science and Engineering, 2021, 18(4): 844–852.
- [7] SPENCER B F, HOSKERE V, NARAZAKI Y. Advances in computer vision-based civil infrastructure inspection and monitoring[J]. Engineering, 2019, 5(2): 199–222.
- [8] ZHANG Lei, YANG Fan, ZHANG Y D, et al. Road crack detection using deep convolutional neural network[C]// 2016 IEEE International Conference on Image Processing (ICIP). September 25–28, 2016, Phoenix, AZ, USA. IEEE, 2016: 3708–3712.
- [9] CHA Y J, CHOI W, BÜYÜKÖZTÜRK O. Deep learning-based crack damage detection using convolutional neural networks[J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32(5): 361–378.
- [10] 沙爱民,童峥,高杰.基于卷积神经网络的路表病害识别与测量[J].中国公路学报,2018,31(1): 1–10.
SHA Aimin, TONG Zheng, GAO Jie. Recognition and measurement of pavement disasters based on convolutional neural networks[J]. China Journal of Highway and Transport, 2018, 31(1): 1–10.
- [11] 王桂平,陈旺桥,杨建喜,等.基于迁移学习的桥梁表观病害检测技术研究[J].铁道科学与工程学报,2022,19(6): 1638–1646.
WANG Guiping, CHEN Wangqiao, YANG Jianxi, et al. A bridge surface distress detection technology based on transfer learning[J]. Journal of Railway Science and Engineering, 2022, 19(6): 1638–1646.
- [12] 晏班夫,徐观亚,栾健,等.基于Faster R-CNN与形态法的路面病害识别[J].中国公路学报,2021,34(9): 181–193.
YAN Banfu, XU Guanya, LUAN Jian, et al. Pavement distress detection based on Faster R-CNN and morphological operations[J]. China Journal of Highway and Transport, 2021, 34(9): 181–193.
- [13] 邹俊志,杨建喜,李昊,等.复杂背景下基于改进YOLO v3算法的桥梁表观病害识别[J].铁道科学与工程学报,2021,18(12): 3257–3266.
ZOU Junzhi, YANG Jianxi, LI Hao, et al. Bridge apparent damage detection based on the improved YOLO v3 in complex background[J]. Journal of Railway Science and Engineering, 2021, 18(12): 3257–3266.
- [14] ZHENG S, SONG Yang, LEUNG T, et al. Improving the robustness of deep neural networks via stability training [C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). June 27-30, 2016, Las Vegas, NV, USA. IEEE, 2016: 4480–4488.
- [15] STARK J A. Adaptive image contrast enhancement using generalizations of histogram equalization[J]. IEEE Transactions on Image Processing, 2000, 9(5): 889–896.
- [16] SHAN Shiguang, WEN Gao, CAO Bo, et al. Illumination normalization for robust face recognition against varying lighting conditions[C]// 2003 IEEE International SOI Conference. October 17–17, 2003, Nice, France. IEEE, 2003: 157–164.
- [17] SAVVIDES M, KUMAR B V K V. Illumination

- normalization using logarithm transforms for face authentication[M]// Lecture Notes in Computer Science. Berlin, Heidelberg: Springer Berlin Heidelberg, 2003: 549–556.
- [18] BELHUMEUR P N, HESPAÑA J P, KRIEGMAN D J. Eigenfaces vs. Fisherfaces: recognition using class specific linear projection[C]// IEEE Transactions on Pattern Analysis and Machine Intelligence. July 1997, IEEE, 2002: 711–720.
- [19] GEORGHIADES A S, BELHUMEUR P N, KRIEGMAN D J. From few to many: illumination cone models for face recognition under variable lighting and pose[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2001, 23(6): 643–660.
- [20] 袁小平, 崔棋纹, 程干, 等. 改进型 Gabor 自商图算法及其在人脸识别中的应用[J]. 计算机工程与应用, 2020, 56(5): 206–213.
YUAN Xiaoping, CUI Qiwen, CHENG Gan, et al. Improved Gabor self quotient image algorithm and its application to face recognition[J]. Computer Engineering and Applications, 2020, 56(5): 206–213.
- [21] 蔡道清, 周洪宇, 覃程锦, 等. 基于小波变换的农田图像光照不变特征提取算法[J]. 农业机械学报, 2020, 51(2): 15–20.
CAI Daoqing, ZHOU Hongyu, QIN Chengjin, et al. Extraction algorithm of illumination invariant feature for farmland image based on wavelet transform[J]. Transactions of the Chinese Society for Agricultural Machinery, 2020, 51(2): 15–20.
- [22] DE BOER P T, KROESE D P, MANNOR S, et al. A tutorial on the cross-entropy method[J]. Annals of Operations Research, 2005, 134(1): 19–67.
- [23] 吴双, 袁野, 马育红, 等. 用于大规模深度卷积分类网络 DOA 估计的标签分解方法[J]. 信号处理, 2021, 37(1): 1–10.
WU Shuang, YUAN Ye, MA Yuhong, et al. Deep convolution neural network label decomposition method for large scale DOA estimation[J]. Journal of Signal Processing, 2021, 37(1): 1–10.
- [24] 李良福, 马卫飞, 李丽, 等. 基于深度学习的桥梁裂缝检测算法研究[J]. 自动化学报, 2019, 45(9): 1727–1742.
LI Liangfu, MA Weifei, LI Li, et al. Research on detection algorithm for bridge cracks based on deep learning[J]. Acta Automatica Sinica, 2019, 45(9): 1727–1742.
- [25] RAHMAN S, RAHMAN M M, ABDULLAH-AL-WADUD M, et al. An adaptive gamma correction for image enhancement[J]. EURASIP Journal on Image and Video Processing, 2016, 2016(1): 1–13.
- [26] DING Jun, CHEN Bo, LIU Hongwei, et al. Convolutional neural network with data augmentation for SAR target recognition[J]. IEEE Geoscience and Remote Sensing Letters, 2016, 13(3): 364–368.
- [27] KWAK Y, SONG W J, KIM S E. Speckle-noise-invariant convolutional neural network for SAR target recognition [J]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(4): 549–553.

(编辑 阳丽霞)