

基于桥梁裂缝识别模型的桥梁裂缝病害识别方法

张振海¹, 季 坤¹, 党建武^{1,2}

(1. 兰州交通大学 自动化与电气工程学院, 兰州 730070; 2. 甘肃省人工智能与图形图像处理工程研究中心, 兰州 730070)

摘要:为实现高效、轻量化、无接触的桥梁裂缝病害识别,提出了一种基于桥梁裂缝识别模型(Bridge crack extraction model, BCEM)的桥梁裂缝识别网络。该网络将深度学习与传统图像处理方法相结合,首先,预处理裂缝图像,增强裂缝信息表达;之后,采用滑窗法将裂缝切分为面元图像,针对面元图像特性,采用改进的BC-MobileNet轻量化模型对裂缝面元进行分类;最后,识别误检与漏检面元,实现桥梁裂缝准确识别。通过与目标检测、模式识别等不同裂缝识别方式进行比较,结果表明:BCEM在各项实验指标上均有提升,证明了本文提出识别网络对桥梁裂缝识别的有效性。

关键词:计算机应用;深度学习;裂缝检测;图像处理;卷积神经网络

中图分类号:TP391.41 **文献标志码:**A **文章编号:**1671-5497(2023)05-1418-09

DOI:10.13229/j.cnki.jdxbgxb.20210860

Crack identification method for bridge based on BCEM model

ZHANG Zhen-hai¹, JI Kun¹, DANG Jian-wu^{1,2}

(1. School of Automation and Electrical Engineering, Lanzhou Jiaotong University, Lanzhou 730070, China; 2. Gansu Province Artificial Intelligence and Graphics and Image Processing Engineering Research Center, Lanzhou 730070, China)

Abstract: To realize high-efficiency, light-weight, and non-contact bridge crack disease identification, a bridge crack identification network based on the (bridge crack extraction model, BCEM) is proposed. The network combines deep learning with traditional image processing methods. First, the crack image is preprocessed to enhance the expression of crack information. Then the sliding window method is used to divide the crack into patches. According to the characteristics of the patches, the improved lightweight model named BC-MobileNet is used to classify crack features. Finally, misdetected and undetected cracks are identified to achieve accurate identification of bridge cracks. Compared with different crack identification methods such as target detection and pattern recognition, the results show that the BCEM has improved in various experimental indicators, which proves the effectiveness of this network for bridge crack identification.

Key words: computer application; deep learning; crack detection; image processing; convolutional neural network

收稿日期:2021-09-02.

基金项目:甘肃省自然科学基金项目(18JR3RA124);甘肃省教育厅青年博士基金项目(2022QB-064);甘肃省优秀研究生“创新之星”项目(2022CXZX-614).

作者简介:张振海(1983-),男,副教授,博士.研究方向:交通信息工程,控制与图像处理.E-mail:764411629@qq.com

0 引言

桥梁工程作为结构工程的主要形式,其发展和演进史伴随了人类文明发展的全过程,与社会、经济、文化、科学、技术等密切相关,是人类科学技术史的重要组成部分^[1]。现如今,我国近百万座桥梁将城乡与各类交通枢纽紧密联系在一起,提升了国家经济活力与国民幸福感。桥梁裂缝作为桥梁严重病害之一,对其高覆盖率、高效的检测成为桥梁工程发展不可缺少的关键环节。目前,基于图像处理的裂缝检测方式由于高精度、快速、非接触、自动采集分析等优点被学者们广泛研究。传统图像处理通过阈值、边缘、区域等方法实现目标提取^[2-4],或通过人工设置特征提取目标^[5,6],其获取目标方式均是通过手动提取图像浅层或中层形态特征,这种基于特征假设的方法在复杂环境下不具备鲁棒性。基于深度学习的图像处理方式随着计算机算力的增长,能充分提取图片深层语义特征,精度更高,抗干扰能力更强,因此被当前学者广泛研究^[7]。在传统分类领域:李良福^[8]、Cha等^[9]通过将桥梁裂缝拆分为小的背景面元与裂缝面元,将裂缝检测问题转化为分类问题,对裂缝进行识别;文献[10-12]通过将ResNet结构与Attention机制结合提高了裂缝识别精确度。在语义分割领域:文献[13-15]使用语义分割算法提取裂缝,并证明该方法的优越性。在目标检测领域:薛亚东等^[16]通过聚类法设置Faster-Rcnn的Anchor-Box尺寸,提升盾构隧道裂缝检测精度;蔡逢煌等^[18]将Mobile-NetV2^[17]作为YOLOV3架构的主干网络,实现轻量化的裂缝识别^[19]。

对于基于语义分割的裂缝识别法,由于裂缝图片场景较传统语义分割目标场景具有环境统一性、裂缝分布无规律性与噪声不确定性,因此识别结果的漏检与误检常常无法预料;对于基于目标检测的裂缝识别法,目标检测使用的桶形定位网络较目标分类使用的锥形网络对噪声更加敏感,无法满足高精度裂缝识别。基于上述分析,本文提出一种将传统图像处理与深度学习图像处理法相结合的桥梁裂缝识别模型(Bridge crack extraction model, BCEM),以实现端到端的裂缝提取。

1 数据集预处理方法

为使分类网络推理结果能泛化在不同的情况下,需要对数据进行预处理。传统数据预处理常使用数据扩增的方式,通过对图像裁剪、对比度调

整、像素填充、随机仿射变换等手段,避免模型过拟合。裂缝图像分类不同于常见目标分类,裂缝目标本身具有不确定性与自相似性^[20],因此上述预处理方法不能带来模型能力提升。本文将传统图像处理中的预处理方法带入本研究,将数据集预处理分为两步:滤波与滑窗裁剪。

1.1 裂缝图片双边滤波

双边滤波作为典型边缘保护滤波器之一,在对像素点滤波时同时考虑了其他像素点距滤波点的位置信息以及其他像素点与滤波点的像素值差异信息。滤波过程如下所示:

$$BF = \frac{1}{W_q} \sum_{p \in S} G_s(p) G_r(p) = \sum_{p \in S} \exp\left(-\frac{\|p - q\|^2}{2\delta_s^2}\right) \exp\left(-\frac{\|I_p - I_q\|^2}{2\delta_r^2}\right) \quad (1)$$

式中:BF为滤波器; W_q 为滤波窗口内每个像素值权重之和; $p-q$ 代表中心点 p 与周围点 q 空间位置之差; $\|I_p - I_q\|$ 表示中心点与周围点像素位置之差; δ_s, δ_r 分别代表像素空间域方差与像素值域方差; G_s 为空间滤波核; G_r 为相似度滤波核; S 为滤波核的空间域。

在本文场景下,该滤波器能够在保护裂缝信息前提下模糊背景,突出裂缝特征。

1.2 裂缝图片滑窗裁剪

本文数据集尺寸为480×320像素,设 W, H 均为16像素, i, j 取值分别为($i=0, 1, \dots, 15$)、($j=0, 1, \dots, 10$)。

数据集扩充过程如图1所示。

为使分类得到的裂缝面元更好拟合实际裂缝,采用滑窗法对使用CCD面阵相机采集得到的1000张480×320大小桥梁裂缝图片按照16×16分辨率的窗口进行裁剪,按照文献[8]中命名法,将有裂缝部分的窗口命名为裂缝面元,其余窗口划分为背景面元。具体步骤如下所示:

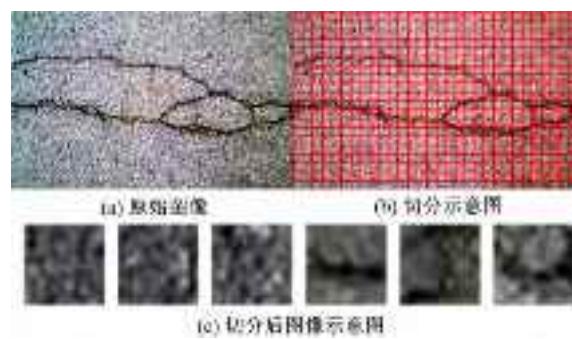


图1 数据集扩充示意图

Fig. 1 Dataset expansion process

$$\begin{cases} imgL_x = i \times W \\ imgL_y = j \times H \\ imgR_x = i \times (W + 1) \\ imgR_y = j \times (H + 1) \end{cases} \quad (2)$$

式中: W 、 H 分别为滑动窗口的宽、高; $imgL_x$ 、 $imgL_y$ 、 $imgR_x$ 、 $imgR_y$ 分别为截取面元的左上角横、纵坐标和右下角横、纵坐标。

2 BC-MobileNet 分类模型

2.1 BC-MobileNet 模型提出原因分析

随着计算机科学的不断发展,深度学习网络结构向深度化、复杂化演进。在 ResNet 网络主干提出后,其中的残差结构^[10]克服了深层网络的梯度消失问题,使更多深层化、多维化的网络结构得以发展。

本文实际应用场景中,为达到全覆盖、便捷、非接触的要求,对桥梁裂缝图片进行提取的研究主要集中在无人机与智能检测机器人等移动设备中。如 Xu 等^[21]、李超飞^[22]均采用无人机进行桥梁图片采集,如图 2 所示。移动端环境限制了大规模网络结构的部署,因此基于模型轻量化的需求与面元图片特性,提出基于 Mobile-NetV2 网络的轻量化可移动部署模型 BC-MobileNet,实现对裂缝采集图片的实时分类。



图 2 兰州中山桥无人机裂缝采集

Fig. 2 UAV crack collection in Zhongshan Bridge, Lanzhou

2.2 MobileNetV2 模型结构

2.2.1 DW 卷积

MobileNetV2 面向移动端网络部署,采用倒残差块结构提取图像特征。当构建轻量化的网络结构时,低维的特征图可以极大节省中间参数,从而提升正向推理的速度。但实验证明线性映射可以保存低层特征信息,而非线性的激活函数在对低维信息进行激活时会破坏特征信息,因此,需要高维特征以保证激活函数可以激活足够的特征信息。倒残差块结构采用跳跃连接,平衡了推理速度与网络提取的特征信息量。

深度可分离卷积(DW 卷积)在文献[23]证明

较于传统块状卷积网络,分层卷积网络在将卷积核的宽与高设置为 3 像素时至少节省 8 倍数据量,卷积核设置为 5 像素时至少节省 23 倍数据量,因此被运用在倒残差块中以减少数据量,从而加速正向推理速度。DW 卷积结构如图 3 所示。

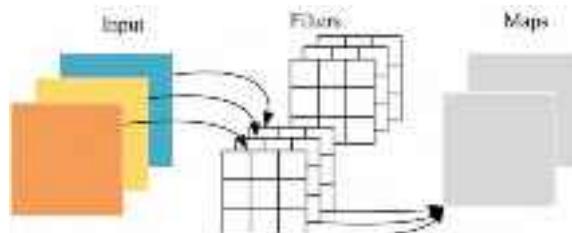


图 3 DW 卷积结构示意图

Fig. 3 Image of DW convolution structure

2.2.2 模型主网络

本文业务场景中,BC-MobileNet 模型使用全卷积网络结构,避免池化层造成信息丢失。模型使用了 5 层卷积层,2 层全连接层,1 个跳跃连接,采用交叉熵作为损失函数。其中,第 1、2、3、5 层卷积层后均使用 ReLU6 作为激活函数,第 4 层卷积层后使用线性激活函数;第一层卷积核大小设置为 5×5 分辨率,其余卷积层设置为 3×3 分辨率;第 1 层与第 5 层卷积层步长设置为 2,其余均为 1。

对桥梁裂缝面元与背景面元的分类问题实际上可归结为二分类问题,因此常用 sigmoid 函数连接最后一个全连接层。但本文面向对象具有一定隐蔽性,部分背景噪声裁剪为面元后很难与裂缝面元分辨。为保证分类准确度,全连接分类层使用 softmax 函数进行激活。模型网络结构如图 4 所示。

(1) 输入 16×16 分辨率的图像

由于 BC-MobileNet 模型设计的目的是为了实现对面元的分类,以获得裂缝面元进而提取裂缝。因此若面元选择 32×32 的分辨率,那么最终提取的面元精度较低,会影响后续从面元中提取裂缝;若面元选择更小的 8×8 分辨率,提取面元精度虽高,但模型感受野降低,很难从如此小的感受野中学到有用的裂缝结构信息。最终,为平衡面元对裂缝的拟合精度与面元分类精度,本文选择 16×16 分辨率面元图像作为分类器的输入。

(2) 增大卷积核

尽管在文献[14]中证明两个 3×3 像素的卷积核在一起相当于 1 个 5×5 像素的卷积核,且具有更少的数据量。但在实际情况中,多个小卷积核堆叠会加深噪声模型表达权重。使用 1 个 5×5 像素卷积核既拥有更大的特征感受野,又有利于模

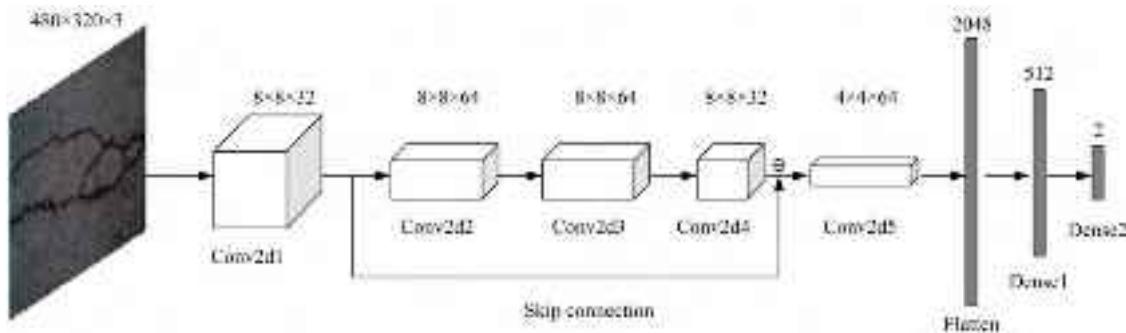


图4 BC-MobileNet网络结构图

Fig. 4 BC-MobileNet network structure diagram

糊与裂缝结构无关的其他噪声信息。因此,BC-MobileNet模型第1层卷积核中使用高分辨率的核尺寸。

(3)降低模型维度

由于桥梁裂缝具有自相似性与一定的拓扑结构,因此结构信息较为简单。在将图片截取为 16×16 分辨率的面元后,噪声结构也相应简单。使用高维度特征图对面元特征表达时常常会包含无用信息、冗余信息等,如噪声与裂缝的位置信息等,这样反而会加大模型训练难度。本文在设置网络结构时将卷积层深度降低至64维。

3 模型后处理

正向推理过程中,桥梁裂缝经过BC-MobileNet模型的处理后,区分了图像中的背景面元与裂缝面元。将面元重组为裂缝图像,中的裂缝面元已经十分逼近实际裂缝真实区域,但在部分面元中仍会出现漏检与误检现象,如图5所示。为更准确定位漏检裂缝面元、隔离误检背景面元、完整提取面元中裂缝部分,提出BCEM模型后处理算法,算法可归纳为以下5步。

(1)算法首先将图像映射为矩阵。对于 $16 \text{ 像素} \times 16 \text{ 像素}$ 分辨率的裂缝图像,矩阵的宽、高分别为30与20,其中裂缝面元矩阵值设为1,背景面元矩阵值设为0。统计每个值为1的裂缝面元其八邻域内同样值为1的裂缝面元,将统

计点大于等于2个点的矩阵点称为中间点,统计点为1的点称为端点,由左上角开始搜索。

(2)计算端点与端点间的最小欧式距离,当该距离小于阈值T时认为这两个端点为断点关系,两点间有漏检的裂缝面元。设置阈值T原因在于避免同一幅裂缝图像出现多道裂缝时被误连接到一起。寻找漏检裂缝面元的方式如图6所示,计算两断点间横纵坐标差值 ΔX 与 ΔY ,若 $\Delta X > \Delta Y$,则以x轴为主轴连接,若 $\Delta X \leq \Delta Y$,则以y轴为主轴连接,按图6所示方式进行断点迭代直至两点重合。设置所找到漏检面元所对应在矩阵中为1。最后,设置集合 $G = \{G_k : k=1, 2, \dots, n\}$,将中的相连点归入同一个 G_k 中。

(3)将集合G中长度小于等于5的集合 G_k 称为孤立集合,这类集合被认为是误检的背景面元,将该集合对应点在矩阵中的值设为0。

(4)将矩阵映射到新的裂缝图像中,对于矩阵值为0的点,该值对应在中的面元部分像素值设为(255, 255, 255);对于矩阵值为1的点,该值对应在中的面元部分像素值与中对应面元像素值相等,映射结果如图7所示,映射过程如下:

$$\begin{aligned} & \text{img}_{L(i \times 16 : i \times (16+1), j \times 16 : j \times (16+1))} = \\ & \quad \begin{cases} \text{img}_{(i \times 16 : i \times (16+1), j \times 16 : j \times (16+1))}, h(i, j) = 1 \\ (255, 255, 255), h(i, j) = 0 \end{cases} \quad (3) \end{aligned}$$



图5 漏检误检现象示意图

Fig. 5 Schematic diagrams of misdetection and undetection

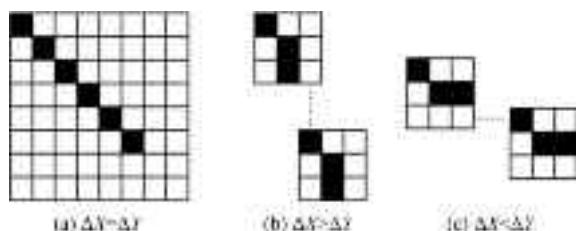


图 6 面元连接方式

Fig. 6 Patches connection method

(5) 对经过上述步骤处理后得到的裂缝图像 img_L , 使用 mask 蒙板遮住像素为 [255, 255, 255] 的部分, 统计算法处理前、后的裂缝灰度直方图如图 8 所示。图 8(a)(b) 中均包含全部的裂缝像素点, 由灰度值分布可知, 算法处理后将图像背景点



图 7 映射过程

Fig. 7 Mapping process

的干扰像素减少了 10 倍。此时由于减少了大量高灰度背景像素点的干扰, 裂缝图像有更为均匀的前景与背景的灰度级分布, 采用 Otsu 阈值分割法更易找到合适的阈值。最终分割得到的图形如图 9 所示。

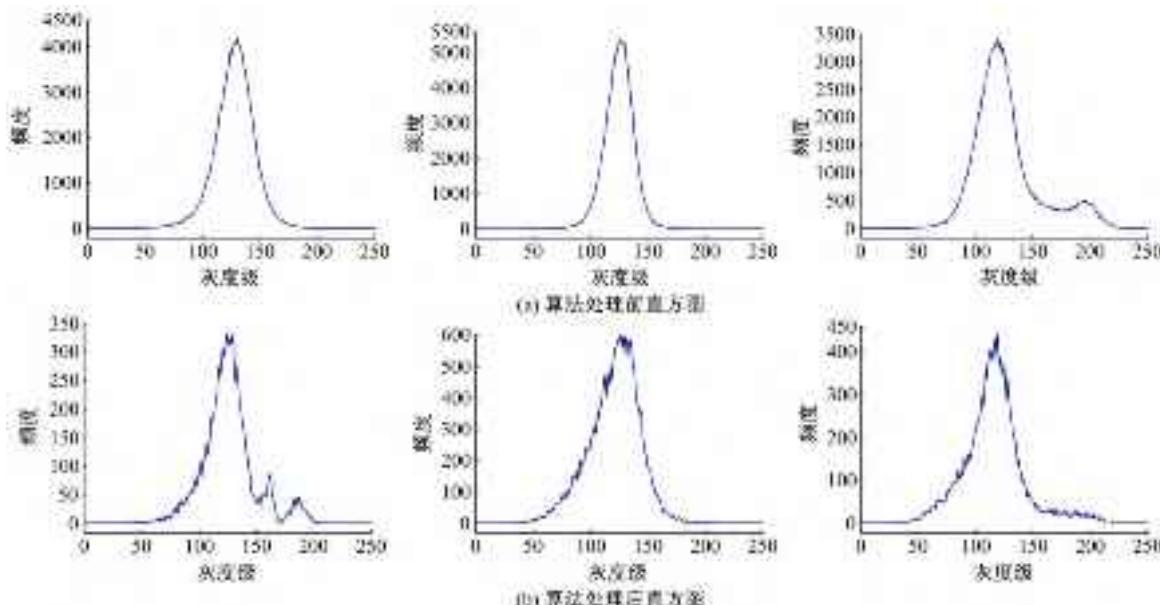


图 8 灰度直方图包络线对比

Fig. 8 Contrast of gray histogram envelopes



图 9 裂缝提取结果

Fig. 9 Crack extraction results

4 实验与结果分析

本文采用 CCD 面阵相机共收集 1000 张 480×320 分辨率的真实桥梁裂缝图片, 对不同的桥梁裂缝图像, 将其面元分别根据 8×8 分辨率、 16×16 分辨率、 32×32 分辨率进行裁剪标注。将标注好的面元图像按照 7:3 的比例随机采样至训练集与验证集, 使用公开裂缝数据集 CrackForest^[24]作为本文测试集, 以保证测试结果公正、客观。实验环境为 Intel(R) Core(TM) i7-6700HQ

CPU, 12 GB 内存, GeForce 1060(6 G)GPU, Windows10 操作系统, 在 Python 的 Tensorflow-gpu 架构上编程实现。

本文分别设计了 3 组对比实验以验证本文所提出 BCEM 模型的科学性、有效性和准确性。其中, 第 1 组实验用于验证预处理方法对 BCEM 模型收敛速度与精度的影响。实验首先将数据集 CrackForest 中的图像按照 16×16 分辨率裁剪并采样 500 张面元作为测试集。实验组使用本文方法对数据集进行预处理, 并训练模型, 对照实验 1 为未使用预处理方法对模型进行训练; 对照实验 2 为使用传统仿射变换等深度学习常见数据扩增方法预处理数据集并训练模型。分别在测试集上测试 3 组模型, 测试结果如表 1 所示, 模型迭代过

表1 预处理方法对BC-MobileNet模型识别算法的影响

Table 1 Influence of preprocessing method for BC-MobileNet model recognition

测试集面元总数	预处理	模型正确识别数	准确率/%
500	否	398	79.6
500	传统方法	389	77.8
500	本文方法	463	92.6

程如图10所示。

由图10分析可知,未进行预处理的数据集在训练初期就出现了过拟合的现象,过拟合前损失函数最低在0.2处。使用传统裁剪、旋转等预处理方式的数据集在训练到第15个epoch时出现过拟合现象,模型训练梯度下降较慢,过拟合前损失

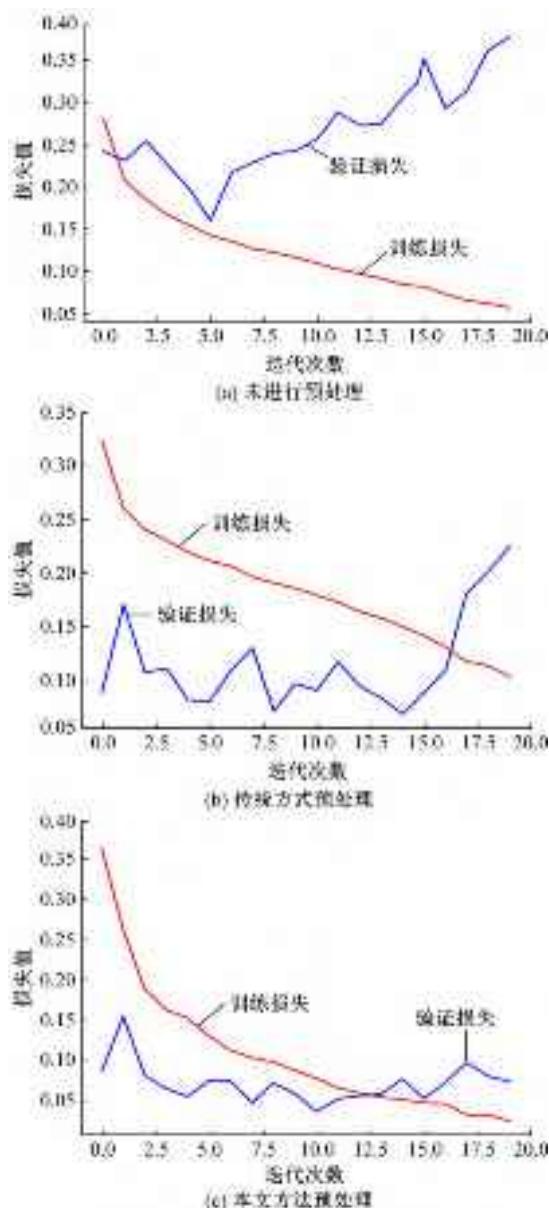


图10 预处理对模型收敛的影响

Fig. 10 Effect of preprocessing on model convergence

函数最低在0.15处。预处理后的数据集在18个epoch到达最低点,模型训练梯度下降较快,损失函数最低在0.01处。结合表1数据可知,采用本文提出的方法对裂缝数据集进行预处理可提升面元识别准确率。

第2组实验用来证明BC-MobileNet提出的合理性,该组实验数据均进行预处理。本组实验共包含两组小实验。实验1:对比VGG网络与MobileNetV2网络对最终实验结果的影响。实验2:将主干网络设置为MobileNetV2,将使用8×8分辨率滑窗的模型设为MobileNetV2-A、使用32×32分辨率滑窗的模型设为MobileNetV2-B、使用大卷积核的模型设为MobileNetV2-C、将对特征图降维的模型设为MobileNetV2-D、以及本文提出的模型BC-MobileNet。实验过程与实验结果如表2所示,可知,通过对VGG-16网络与MobileNetV2的对比,证明使用MobileNetV2的相对稀疏网络结构更容易收敛面元图像。通过对MobileNetV2、MobileNetV2-A与MobileNetV2-B的对比可知,8×8分辨率的面元难以获取足够结构信息,因此效果不理想,32×32分辨率的滑窗对面元有更好的识别效果,相较16×16分辨率的滑窗有近6个点的提升,但因综合考虑到滑窗对实际裂缝拟合精度的影响,最终选择16×16分辨率作为滑窗尺寸。通过对MobileNetV2-C、MobileNetV2-D与MobileNetV2的对比,证明了增大卷积核与降低模型维度对裂缝面元识别精度有提升的作用。通过对BC-MobileNet模型与表2所有其他模型的对比可知,本文模型对面元识别具有良好效果。

第3组实验用来对比目前各种裂缝提取算法对裂缝提取结果的准确度影响。由于目标提取算法只能定位裂缝位置,不能实现裂缝像素级分割

表2 各类模型对面元识别的影响

Table 2 Influence of various models on patches recognition

主干网络	测试集	面元规格	识别准	识别召
	面元数	/像素	确率/%	回率/%
VGG-16	500	16×16	16.7	62.4
MobileNetV2	500	16×16	67.2	73.6
MobileNetV2-A	500	8×8	40.7	52.8
MobileNetV2-B	500	32×32	76.8	83.0
MobileNetV2-C	500	16×16	71.8	85.3
MobileNetV2-D	500	16×16	75.0	81.8
BC-MobileNet	500	16×16	92.6	94.1

提取,因此将本实验细分为 2 个小实验。第 1 组小实验用来比较 BCEM 与 Faster-Rcnn 目标检测模型的定位精度。实验步骤如下:由于测试集 CrackForest 具有像素级的语义分割标注 CrackForestgt,因此首先将 CrackForestgt 通过最小矩形框标记作为目标检测的 GroundTruth。然后从测试集抽取 100 张图像,使用本文提出的 BCEM 面元识别模型对裂缝面元进行识别与后处理,统计所有面元图像,找到左上角坐标与右下角坐标。接下来,使用目标检测模型对裂缝识别,微调目标检测网络结构以适应本文面向对象并提取检测框的左上角坐标与右下角坐标,最后,使用 IoU (Intersection over Union) 值与 AP 值作为衡量模型定位结果与 GroundTruth 的定量标准。为简化计算,IoU 计算仅选取正样本,忽略负样本。比较结果如表 3 所示,计算过程为:

$$IoU = \frac{\text{interArea}}{\text{boxAArea} + \text{boxBArea} - \text{interArea}} \quad (4)$$

式中: interArea 为推理框与真实框的交集大小; boxAArea 为推理框的大小; boxBArea 为真实框的大小。

由表 3 分析可知,由于在数据预处理与后处理阶段没有图形处理器(GPU)加速,因此 BCEM

表 3 BCEM 与目标检测模型对面元识别准确率的影响

Table 3 Influence of BCEM and target detection model on the accuracy of panel recognition

模型	测试集面元数	平均识别 IoU	AP	识别速度/(s·面元 ⁻¹)	模型大小/Mbit
BCEM	500	0.98	0.9555	1.762	19.9
Faster-Rcnn	500	0.87	0.9073	1.152	127
YoLoV3	500	0.82	0.9019	0.089	69

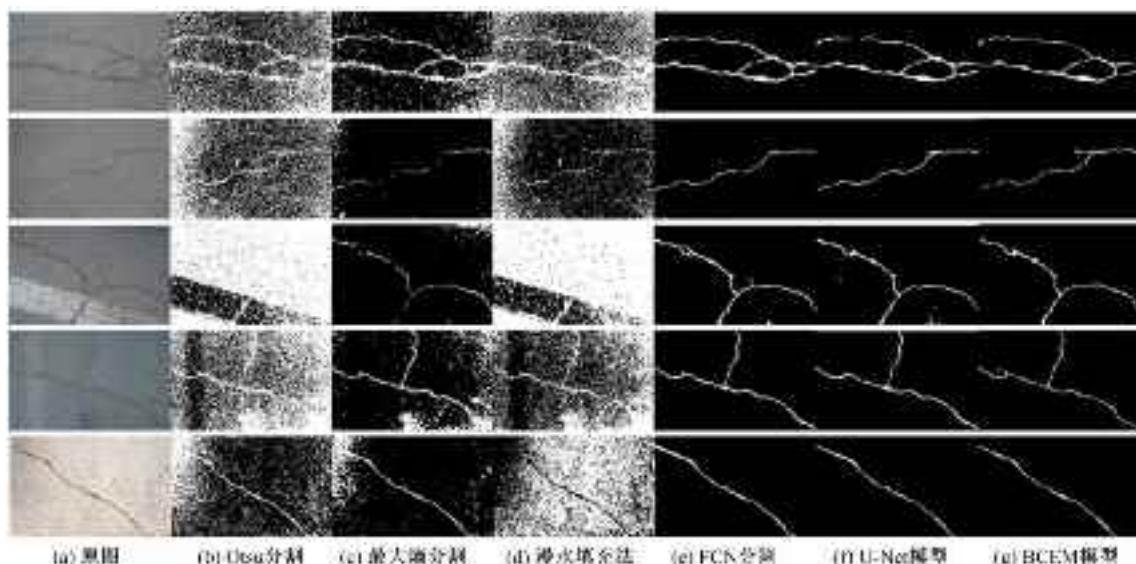


图 11 各类算法模型对裂缝的提取结果

Fig. 11 Extraction results of cracks by various algorithm models

相较目标检测整体运行时间较长,但 BCEM 具有高识别率、高准确度与轻量化的优势,第 1 组小实验证明了使用本文提出 BCEM 较目标检测模型性能更好。

第 2 组小实验用来测试 BCEM 与传统分割算法模型 Otsu、最大熵分割、漫水填充法,语义分割模型 FCN、U-Net 的裂缝提取精度。从测试集随机抽取 100 张裂缝图片,比较本文算法模型与其他模型对这些图片的提取效果。以像素级查准率 pr 、查全率 re 对模型识别能力进行定量分析, pr 与 re 定义如下所示:

$$pr = \frac{TP}{TP + FP} \quad (5)$$

$$re = \frac{TP}{TP + FN} \quad (6)$$

式中: TP 为正确识别的裂缝像素点数量; FP 为错误识别的裂缝像素点数量; FN 为错误识别的背景点数量。

比较结果如图 11 与表 4 所示。通过如图 11 所示实验与表 4 所示量化指标分析可知,传统算法具有更小的模型和更快的计算速度,通常是因为传统算法仅对图像像素值遍历 2~10 次左右,没有复杂的前向推理步骤。但传统算法的识别精

表4 各类模型提取裂缝指标分析

Table 4 Analysis of fracture index extracted by various models

模 型	测试集图 片数	<i>pr</i> /%	<i>re</i> /%	模型大小 /Mbit
Otsu	100	15.7	16.3	—
最大熵分割	100	39.7	52.4	—
漫水填充	100	7.8	7.5	—
FCN	100	72.2	75.2	39
U-Net	100	81.7	83.4	28
ANet-FSM ^[25]	100	88.46	87.0	40
HDCB-Net ^[26]	100	91.44	86.35	64
BCEM	100	97.5	98.7	19.9

度与查全率较低,尤其在干扰严重的图像中传统方法表现较差(如图11第3行图像,由于加入了大片白色的油漆噪声,严重影响了漫水填充与Otsu的识别结果)。

ANet-FSM与HDCB-Net模型有相对较好的结果,但这两种模型面向高分辨率网络,只能输入整张图像进行计算,无形中提高了数据集的标注要求。由于目前公开的裂缝数据集极其有限,裂缝识别从某种程度上可归结为小样本识别问题,本文提出的滑窗裁剪法既对裂缝拟合精度高,同时也是一种数据集扩增的方法。综合而言,BCEM模型具有更好的效果与泛化能力,比语义分割模型更具优势。

5 结束语

本文提出将深度学习模型与传统图像处理方式相结合的BCEM裂缝提取模型。针对裂缝特征与采集裂缝数据集的图片特性,分别从预处理方式、滑窗大小、模型参数微调、模型后处理等不同角度讨论BCEM的设计原理,详细介绍了模型的结构。证明了本模型既具有深度网络的前向推理能力,又具有传统模型的可解释性。将本模型与目标检测、语义分割模型进行对比,定量地证明本模型在提取桥梁裂缝方面具有更好的识别能力与移动部署能力。

对于本模型的下一步改进在于对裂缝的后处理连接模块,人工阈值的设置对模型可泛化性具有一定影响,同时,模型在识别能力与推理速度上还有提高的空间,需要进行进一步研究。

参考文献:

[1]《中国公路学报》编辑部.中国桥梁工程学术研究综

述·2021[J].中国公路学报,2021,34(2):1-97.

Editorial Department of China Journal of Highway and Transport. A summary of academic research on Chinese bridge engineering·2021[J]. Journal of China Highway, 2021, 34(2): 1-97.

- [2] Song B, Wei N. Statistics properties of asphalt pavement images for cracks detection[J]. Journal of Information & Computational Science, 2013, 10(9): 2833-2843.
- [3] Zou Q, Zhang Z, Li Q Q, et al. Deepcrack: learning hierarchical convolutional features for crack detection [J]. IEEE Trans Image Processing, 2019, 28(3): 1498-1512.
- [4] 肖明尧,李雄飞,张小利,等.基于多尺度的区域生长的图像分割算法[J].吉林大学学报:工学版,2017,47(5): 1591-1597.
Xiao Ming-yao, Li Xiong-fei, Zhang Xiao-li, et al. Image segmentation algorithm based on multi-scale region growth[J]. Journal of Jilin University(Engineering and Technology Edition), 2017, 47(5): 1591-1597.
- [5] Qu Z, Chen S Q, Liu Y Q, et al. Linear seam elimination of tunnel crack images based on statistical specific pixels ratio and adaptive fragmented segmentation [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21: 3599-3607.
- [6] 谢志江,吕波,刘琴,等.旋转不变性图像模板匹配快速算法[J].吉林大学学报:工学版,2013,43(3): 711-717.
Xie Zhi-jiang, LYU Bo, Liu Qin, et al. A fast algorithm for image template matching with rotation invariance[J]. Journal of Jilin University(Engineering and Technology Edition), 2013, 43(3): 711-717.
- [7] Zhao B, Dai M, Li P, et al. Defect detection method for electric multiple units key components based on deep learning[J]. IEEE Access, 2020, 8: 136808-136818.
- [8] 李良福,马卫飞,李丽,等.基于深度学习的桥梁裂缝检测算法研究[J].自动化学报,2019,45(9): 1727-1742.
Li Liang-fu, Ma Wei-fei, Li Li, et al. Research on bridge crack detection algorithm based on deep learning[J]. Automatica Sinica, 2019, 45(9): 1727-1742.
- [9] Cha Y J, Choi W, Oral B. Deep learning-based crack damage detection using convolutional neural networks[J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32(5): 361-378.
- [10] He K M, Zhang X Y, Ren S Q, et al. Deep residual

- learning for image recognition[C]//IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA, 2016: 770–778.
- [11] Rahul K, Ankur G, Harkirat S A, et al. CBSN: comparative measures of normalization techniques for brain tumor segmentation using SRCNet[J]. *Multimedia Tools and Applications*, 2022, 81(10): 13203–13235.
- [12] 曹锦纲, 杨国田, 杨锡运. 基于注意力机制的深度学习路面裂缝检测[J]. *计算机辅助设计与图形学学报*, 2020, 32(8): 1324–1333.
Cao Jin-gang, Yang Guo-tian, Yang Xi-yun. Deep learning pavement crack detection based on attention mechanism[J]. *Journal of Computer Aided Design and Graphics*, 2020, 32(8): 1324–1333.
- [13] 黄宏伟, 李庆桐. 基于深度学习的盾构隧道渗漏水病害图像识别[J]. *岩石力学与工程学报*, 2017, 36(12): 2861–2871.
Huang Hong-wei, Li Qing-tong. Image recognition of water leakage in shield tunnels based on deep learning[J]. *Chinese Journal of Rock Mechanics and Engineering*, 2017, 36(12): 2861–2871.
- [14] Simonyan S, Zisserman A. Very deep convolutional networks for large-scale image recognition[J/OL]. [2015-04-10]. <https://doi.org/10.48550/arXiv.1409.1556>
- [15] Islam M M M, Kim JM. Vision-based autonomous crack detection of concrete structures using a fully convolutional encoder-decoder network[J]. *Sensors(Basel)*, 2019(19): 19194251.
- [16] 薛亚东, 李宜城. 基于深度学习的盾构隧道衬砌病害识别方法[J]. *湖南大学学报: 自然科学版*, 2018, 45(3): 100–109.
Xue Ya-dong, Li Yi-cheng. A method of disease recognition for shield tunnel lining based on deep learning [J]. *Joumal of Hunan University(Natural Sciences)*, 2018, 45(3): 100–109.
- [17] Sandler M, Howard A, Zhu M, et al. MobileNetV2: inverted residuals and linear bottlenecks[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018: 4510–4520.
- [18] Redmon J, Farhadi A. YOLOv3: an incremental improvement[J/OL]. [2018-04-08]. <https://doi.org/10.48550/arXiv.1804.02767>
- [19] 蔡逢煌, 张岳鑫, 黄捷. 基于 YOLOv3 与注意力机制的桥梁表面裂痕检测算法[J]. *模式识别与人工智能*, 2020, 33(10): 926–933.
Cai Feng-huang, Zhang Yue-xin, Huang Jie. Bridge surface crack detection algorithm based on YOLOv3 and attention mechanism[J]. *Pattern Recognition and Artificial Intelligence*, 2020, 33(10): 926–933.
- [20] Saouma V E, Barton C C, Gamaleldin N A. Fractal characterization of fracture surfaces in concrete[J]. *Engineering Fracture Mechanics*, 1990, 35(1-3): 47–53.
- [21] Xu F Y, Jiang Q S. Dynamic obstacle surmounting analysis of a bilateral-wheeled cable-climbing robot for cable-stayed bridges[J]. *The Industrial Robot*, 2019, 46(3): 431–443.
- [22] 李超飞. 桥梁病害检测的无人机地面站软件设计与实现[D]. 西安: 长安大学电子与控制工程学院, 2020.
Li Chao-fei. Design and implementation of UAV ground station software for bridge disease detection [D]. Xi'an: School of Electronics and Control Engineering, Chang'an University, 2020.
- [23] Howard A G, Zhu M, Chen B, et al. MobileNets: efficient convolutional neural networks for mobile vision applications[J/OL]. [2017-04-17]. <https://doi.org/10.48550/arXiv.1704.04861>
- [24] Shi Y, Cui L M, Qi Z Q, et al. Automatic road crack detection using random structured forests[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2016, 17(12): 3434–3445.
- [25] Billah U H, La H M, Tavakkoli A. Deep learning-based feature silencing for accurate concrete crack detection[J]. *Sensors*, 2020, 20(16): 20164403.
- [26] Jiang W B, Liu M, Peng Y N, et al. HDCB-Net: a neural network with the hybrid dilated convolution for pixel-level crack detection on concrete bridges[J]. *IEEE Transactions on Industrial Informatics*, 2021, 17(8): 5485–5494.