



基于迁移学习的桥梁表观病害 检测技术研究

王桂平², 陈旺桥¹, 杨建喜¹, 唐于凌², 吴波¹

(1. 重庆交通大学 信息科学与工程学院, 重庆 400074;
2. 重庆交通大学 土木工程学院, 重庆 400074)

摘要: 桥梁表观病害检测是保证桥梁设施安全的关键技术之一。深度卷积网络因其强大的特征提取能力, 被广泛应用于土木工程领域的结构病害识别与检测, 然而在土木工程领域中往往缺乏用于训练深度学习网络的高质量大规模病害图像数据集。针对上述问题, 提出一种基于迁移学习的桥梁表观病害检测方法。该方法运用迁移学习技术, 通过迁移VGG16网络模型结构及全部卷积层参数, 并在迁移后的模型结构上添加新的全连接层, 以此来解决训练数据集不足的问题。运用动态学习率调整策略, 以不同的学习率对卷积层和全连接层参数分别进行微调, 用于提高模型的识别准确率。实验对比ResNet18, ResNet50, VGG19, VGG16等主流深度学习网络模型, 该方法在验证集上取得了最高准确率, 为98.86%。用实拍的未经过处理的桥梁表观病害图像数据集进行测试, 该方法的整体结构表观病害识别准确率达到88.33%, 其中泛碱、露筋和裂缝3类病害的测试准确率分别达到96.25%, 80.00%和88.75%, 具有较高的病害识别准确率, 可以用于在役桥梁表观病害识别。

关键词: 桥梁表观病害检测; 迁移学习; 深度卷积网络; 动态学习率调整; 微调

中图分类号: TP391

文献标志码: A

开放科学(资源服务)标识码(OSID)

文章编号: 1672-7029 (2022) 06-1638-09



A bridge surface distress detection technology based on transfer learning

WANG Guiping², CHEN Wangqiao¹, YANG Jianxi¹, TANG Yuling², WU Bo¹

(1. School of Information Science and Engineering, Chongqing Jiaotong University, Chongqing 400074, China;

2. School of Civil Engineering, Chongqing Jiaotong University, Chongqing 400074, China)

Abstract: Bridge surface distress detection is one of the key technologies to ensure the safety of bridge facilities. Deep convolution network is widely used in the identification and detection of structural damages in civil engineering due to its powerful feature extraction capability. However, in the field of civil engineering, there is often a lack of high-quality large-scale distress image datasets for training deep learning network. To solve the above problems, a bridge surface distress detection method based on transfer learning was proposed. The method used the transfer learning technology to solve the problem of insufficient training dataset by migrating the

收稿日期: 2021-06-22

基金项目: 国家自然科学基金资助项目(62073051); 重庆市教委科学技术研究项目青年项目(KJQN201900726); 重庆市教委科学技术研究重大项目(KJZD-M202000702)

通信作者: 王桂平(1979-), 男, 江西吉安人, 副教授, 博士, 从事交通基础设施状态监测、损伤识别研究; E-mail: wgp@cqjtu.edu.cn

VGG16 network model structure and all convolution layer parameters and adding a new full connection layer to the migrated model structure. The dynamic learning rate adjustment strategy was used to fine-tune the parameters of the convolution layer and the full connection layer with different learning rates to improve the recognition accuracy of the model. Compared with the mainstream deep learning network models such as ResNet18, ResNet50, VGG19 and VGG16, this method achieved the highest accuracy of 98.86% in the validation set. As tested by the unprocessed bridge surface distress image dataset, the overall structural surface distress identification accuracy of this method reached 88.33%. Among them, the test accuracy of corrosion, exposed rebar and cracks reached 96.25%, 80.00% and 88.75%, respectively, which has a high distress identification accuracy and can be used to identify surface distress of in-service bridges.

Key words: bridge surface disease detection; transfer learning; deep convolution network; dynamic learning rate adjustment; fine-tune

桥梁作为交通运输的重要枢纽，在国民经济与社会发展中占据着重要地位。随着服役年限的增加，以及自然环境、施工缺陷和超载因素等，桥梁结构会出现不同程度的损伤和病害，如开裂、下挠和锈蚀等^[1]。传统的人工检测方法存在主观性强、检测效率低下等问题，不能及时发现桥梁病害，不能适应时代发展的需求。深度卷积神经网络^[2]具有强大的特征提取能力，能够发现并刻画问题内部复杂的结构特征，在计算机视觉以及语音识别方面的效果远超传统方法。这些优点让土木工程领域的研究人员和工程师已经注意到基于深度学习的方法带来的应用前景和创新技术力量^[3-4]。在土木工程应用方面，基于深度学习的混凝土病害检测大多集中在混凝土结构的裂缝检测^[5-10]。另外，卷积神经网络模型也常常用来检测隧道缺陷^[11]、路面裂缝的检测^[12]和多病害损伤分类识别^[13]。结合深度学习技术，结构病害检测技术在土木工程领域取得了良好的发展。然而，在实际应用中，数据集的收集和标注往往既耗时又昂贵，这使得深度学习在一些场景下存在一定的局限性^[14]。为了克服缺乏特定任务的标注数据集的问题，可以采用迁移学习技术^[15-16]。迁移学习可以将深度学习模型在一些大数据集(如ImageNet^[17])上学到的一般知识，迁移到特定的小数据集上，以克服数据样本数量不足的问题，从而避免模型过拟合，提高模型的训练速度。NARAZAKI等^[18]利用预训练全卷积网络作为特征提取器对桥梁构件进行自动识别。LIANG^[19]提出将迁移学习应用于钢筋

混凝土桥梁的灾后检测，实现桥梁系统级故障分类、构件级立柱检测和局部损伤等级损伤定位。DUNG等^[20]提出使用深度学习技术来检测钢桥接头的裂缝。通过使用VGG16预训练模型作为特征提取工具来提取不同图像的共有特征。KIM等^[21]提出了一种基于深度学习的自动裂纹检测方法，用于检测真实结构上拍摄的图像上的裂纹。这种方法使用预训练AlexNet进行微调和训练，以检测完整表面和没有裂缝的物体上的裂缝。YANG等^[22-23]使用了一种基于VGG骨干网络的深度全卷积网络(FCN)的裂缝检测方法来自动检测混凝土表面的裂缝。VALIKHANI等^[24]使用预先训练的ResNet网络模型作为骨干网络，从图像数据中提取特征以定量估计混凝土表面粗糙度。CAO等^[25]提出了使用迁移学习的DenseNet方法来识别和分类混凝土构件的表面裂缝。NI等^[26]提出了使用基于深度学习的预训练GoogleNet和ResNet相结合的裂缝检测方法来定量检测裂缝宽度的损伤检测。韩晓健等^[27]使用预训练AlexNet网络模型来对桥梁病害进行分类，在模型实际应用中，3种病害图像的识别率分别为裂缝86%，锈蚀82%，缺损70%。然而，上述工作大多是针对某类单一病害进行检测，例如混凝土裂缝病害，无法满足实际应用中检测多种病害的情况。而本研究通过运用迁移学习技术，有效地缓解了因训练样本不足而引起的模型效果差的问题，并且能够适应于多种病害的检测，对在役桥梁表观病害识别有重大的意义。

1 研究方法

1.1 研究思路

本文提出桥梁表观病害检测算法的主要步骤为：首先将收集到的桥梁表观病害图片数据集进行增强与预处理；使用VGG16网络模型作为主干网络，基于迁移学习技术，把在ImageNet^[14]上预训练得到的权重参数作为其初始参数，修改模型的全连接层和输出层结构，使其对应于病害类别，并将模型参数进行重新训练微调，在训练过程中使用动态学习率调整策略重新训练微调卷积层和全连接层的参数部分，并始终保持全连接层学习率大于卷积层学习率，使全连接层的参数快速收敛，并使得修改后的模型适用于桥梁病害检测任务；最后将处理好的图片输入到网络进行训练，并将其结果与AlexNet、VGG19、ResNet18和ResNet50等主流模型进行实验结果比对。

1.2 迁移学习技术

迁移学习：给定一个源域 D_s 和一个学习任务 T_s ，以及一个目标域 D_t 和一个学习任务 T_t ，迁移学习目的是使用源域 D_s 中的知识和学习任务 T_s 来帮助改进目标域 D_t 中的目标预测函数 $f_t(\cdot)$ 的学习。

一个域由2部分组成 $D = \{\chi, P(X)\}$ ，其中 χ 为特征空间， $P(X)$ 为边缘概率分布。当 $D_s \neq D_t$ 时，意味着它们所对应的特征空间和边缘概率分布函数也是不同的；相类似的，一个任务也是由2部分组成 $T = \{\gamma, f(\cdot)\}$ ，其中 γ 为标签空间， $f(\cdot)$ 为目标预测函数。当 $T_s \neq T_t$ 时，意味着它们对应的标签空间和目标预测函数也是不相同的。使用迁移学习技术，知识能够在不同的领域中进行迁移，加快了任务的学习速度，并且减少了任务对于目标域中样本的依赖。迁移学习的目标是在目标域学习一个更为准确的决策函数。整个迁移学习过程如图1所示。

机器学习的理想场景是拥有大量与测试数据具有相同分布的标记训练样本。但在现实生活中，获取大量的标签数据往往代价高昂且不切实际。迁移学习作为一种很有前途的机器学习方法，通

过迁移领域间的知识，解决了数据样本获取困难的问题。利用迁移学习技术，可以实现知识在不同领域之间的传递。




图1 迁移学习原理

Fig. 1 Principle of transfer learning

1.3 基于迁移学习的桥梁表观病害检测模型

VGG16是一种经典的深度卷积神经网络，它对ImageNet数据库中的100多万幅图像进行分类训练，并被广泛用作参考模型。ImageNet数据集中涵盖了1 000个不同的物体类别，其中包含着丰富的特征知识，由该数据集训练得到的VGG16模型，能够提取其中丰富的图片特征，并将学到提取特征知识的能力以及相关知识以参数的形式记录在模型的卷积层中，而这一部分是可迁移的。因此，本研究选择VGG16作为迁移学习研究的基础模型。该模型有16层、1.38亿个参数，VGG16可将图像分类为1 000个目标类别，可信度高，如图2所示。

结合迁移学习理论以及深度学习框架，本文提出了一种基于端到端的深度卷积神经网络的迁移学习方法，用于检测桥梁表观病害，该方法的模型结构如图3所示。该模型将ImageNet数据集作为源域，将桥梁表观病害数据集作为目标域，将VGG16网络模型作为知识载体，通过利用VGG16在ImageNet学习到的知识以及分类任务来帮助提升目标域中的决策函数的学习能力，加快了任务的学习速度，并且减少了任务对于目标域中样本的依赖。

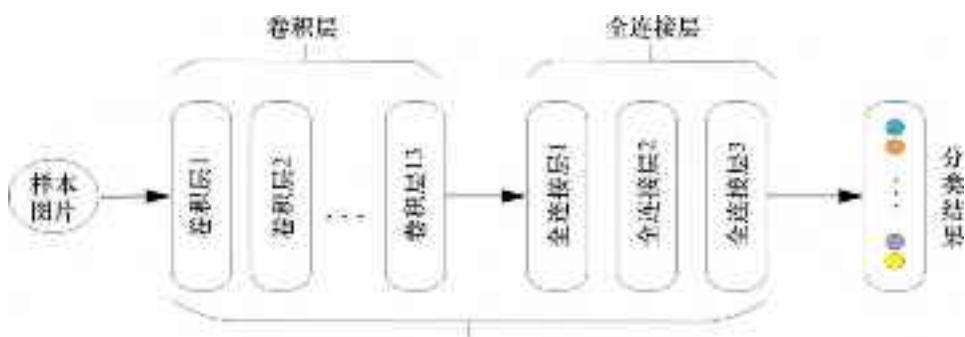


图2 VGG16网络模型

Fig. 2 VGG16 network model




图3 基于迁移学习的桥梁表观病害检测模型

Fig. 3 Bridge surface disease detection model based on transfer learning

VGG16卷积层部分具有强大的特征提取能力, 卷积层的前端能提取图片的一般特征, 随着卷积层的增加, 其所提取的特征也越为具体, 能够有效地提取图片中的细微特征。为了提高病害检测准确性以及节省有限计算资源, 本研究对VGG16网络结构进行修改, 保留其原有的卷积层用于病害特征提取, 然后将其原有的全连接层去掉并添加新的分类层, 以适应桥梁病害分类任务。其中卷积层参数初始化使用在大型图像分类数据集ImageNet上预训练参数, 并随机初始化全连接层参数。在模型训练阶段, 对卷积层参数和全连接层参数采用不同的学习率进行微调, 运用动态学习率调整策略, 能有效提高模型的检测准确率, 使该模型适用于桥梁表观病害检测问题。

2 数据预处理

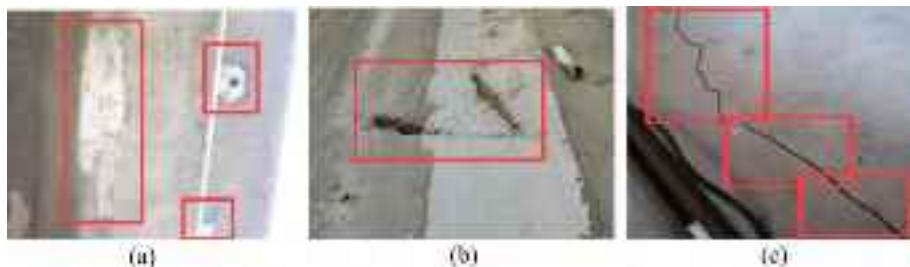
随着卷积神经网络的快速发展, 在图像识别、语音识别等领域积累了一些标准数据集, 如ImageNet, CoCo和Pascal VOC。然而, 在土木工

程领域中缺乏用于训练深度网络模型的高质量桥梁表观病害图像数据集。针对上述问题, 本文经过多年的数据积累, 构建了一个桥梁表观病害数据集。该数据集使用配备高清摄像头的摄像机进行数据集拍摄。桥梁表观病害包含露筋、泛碱、裂缝、混凝土掉块、蜂窝麻面、漏水、空洞、风化等多种病害, 而目前所收集到的数据集的病害大多集中在露筋、泛碱和裂缝3类, 故主要选取该3类病害作为主要病害数据集进行实验研究, 这3类病害图片如图4所示。其中每类图像都是由不同桥梁病害数据集组成, 每张图片的像素都在1 200万以上。

由于原始图像包含复杂的背景和噪声, 为了增强这些图像, 从每类病害各挑选360张图片作为训练集, 并且将训练集中的每张原始图像随机分割为50张 250×250 像素大小的图片, 在切割后的数据集中为每类病害挑选1 300余张图像。在挑选的过程中按照病害特征清晰可见, 并且病害特征大小占据整张图像大小的15%以上面积的原则进行挑选。然后, 将每种标签类型按照8:2分为3

个子集，分别用作模型的训练和验证。此外为每类病害各挑选80张未经过随机分割处理且包含复

杂背景和噪声的图像作为测试集。表1列出了训练、验证和测试数据集的分布。



(a) 泛碱; (b) 露筋; (c) 裂縫

图4 桥梁表面病害

Fig. 4 Bridge surface diseases

表1 数据集的分布

Table 1 Distribution of datasets

标签类别	子数据集/张		
	训练集	验证集	测试集
泛碱	1 056	256	80
露筋	1 056	267	80
裂縫	1 033	255	80

3 实验设置与结果分析

该项实验使用深度学习框架Pytorch为所提出的病害检测模型进行参数训练。实验设置：采用随机梯度下降法，batchsize为32，初始学习率设置为 5×10^{-3} ，冲量(Momentum)设置为0.9，衰量(Decay)为 5×10^{-4} ，采用交叉熵损失函数。实验的硬件环境配置见表2。

表2 实验硬件环境配置

Table 2 Experimental hardware environment configuration

硬件名称	型号
CPU	Intel Core i9-9900K
内存	金士顿 64 G
GPU	NVIDIA RTX 3090

3.1 评价指标

实验采用准确率作为评价指标。准确率是反映一个模型对实际样本数据判断与样本标签比对的结果。准确率越高，则说明模型的效果越好。准确率的一般公式为：

$$ACC = \frac{TN + TP}{TN + FN + FP + TP} \quad (1)$$

其中： TP 是正确检测到的桥梁表面病害图片的数目， TN 是正确检测到的非病害图片的数目， FP 是被视为病害图片的非病害图片的数目， FN 是被视为非病害图片的病害图片的数目。

另外，实验的loss损失也是判断模型性能的另一个方面指标。loss函数数值下降越快，则说明模型收敛得越快；loss损失函数的数值越小，则说明模型的鲁棒性越强，性能越优越。

3.2 动态学习率调整策略

学习率通常指的是深度学习以及监督学习中一个重要的超参数，它决定着模型能否收敛到最优以及收敛到最优的时间。当学习率设置过小时，会使得模型收敛过慢，可能会导致模型陷入局部最优点，以至于很难到达模型目标函数最优点；当学习率过大时，能够使得模型快速收敛，但是有可能会使得模型到达最优点之前反复震荡，以至于无法到达最优。因此，选择合适学习率对一个模型的收敛极为重要。

本研究使用动态学习率调整策略，随着模型的迭代次数加深会逐步减小学习率，该策略参考自GANIN等^[28]的工作。该策略能够使得模型在初始训练阶段能够快速收敛，跳过一些局部最优点，随着迭代次数加深，学习率降低，模型所能学到的特征随之增加，模型的识别准确率随之提升。动态学习率调整策略如下：

$$LR_schedule = \frac{LR}{\left(1 + \frac{10 \times epoch}{n_epoch}\right)^{0.75}} \quad (2)$$

其中： LR 为设置的初始学习率大小； $epoch$ 为当前

训练轮次数目; n_{epoch} 为实验设置的总轮次数目。在训练过程中, 初始学习率 LR 和总轮次数目 n_{epoch} 不变, 当前训练轮次数目 $epoch$ 会逐渐增大, 从而导致训练学习率 $LR_{schedule}$ 会随着训练轮次的增加而逐步缓慢地减小。经过动态学习率调整后, 模型的精度变化如表 3 所示, 其中 VGG16_lr_schedule 和 ResNet50_lr_schedule 表示基于动态学习率调整的 VGG16 网络模型。从表 3 所示的实验结果可以发现, 通过动态学习率调整策略的模型的精度均高于未经过该策略调整的精度。

3.3 全连接层层数的选取

在本研究提出的方法中, 从 VGG16 模型中共迁移了 13 个卷积层, 并在其后面添加了全连接层 (FC, Fully Connected Layer)。在不同 FC 层数的情况下, 对于每种模型的性能进行了评估。如表 4 所示, 采用双 FC 层的模型, 总体检测准确率最高 98.86%, 其中泛碱、露筋和裂缝的检测准确率为 98.49%, 98.04% 和 100%。由此结果可以得出, 迁移过来的卷积层可以有效地提取病害特征, 并且

可以适应新的分类任务。1 个 FC 层和 2 个 FC 层相比, 随着 FC 层数的增加, 模型识别准确率也增加, 说明模型的非线性映射能力得到提高; 然而当 FC 层数增加到 3 层之后, 与使用 2 个 FC 层相比, 模型精度有所下降, 这是由于对于小分类问题, 随着层数的增加, 模型会把一些不必要的特征当作判断依据, 影响了模型的判断, 使得模型的精度下降。因此, 在本研究的模型中, 2 个 FC 层就足够了。

表 3 动态学习率调整策略下的模型精度变化

Table 3 Model accuracy under the dynamic learning rate adjustment strategy

模型	验证精度/%	各类病害识别精度/%		
		泛碱	露筋	裂缝
VGG16	88.18	88.30	77.65	98.13
VGG16_lr_schedule	96.70	95.47	95.29	99.25
Resnet50	95.04	93.58	92.16	99.25
ResNet50_lr_schedule	95.17	95.85	90.20	99.25

表 4 不同全连接层数对实验结果的影响

Table 4 Influence of different fully connected layers on the experimental results

VGG16 预训练 模型参数	全连接层 层数/层	卷积层是否 可训练	训练轮 数/次	验证集准确率(ACC/%)			
				总体准确率	泛碱	露筋	裂缝
可用	1	是	150	98.22	98.49	96.08	100
可用	2	是	150	98.86	98.49	98.04	100
可用	3	是	150	98.73	98.48	98.01	99.71

3.4 微调

微调是基于深度学习的迁移学习方法中常用的技术手段。通常情况下, 微调技术是指: 在一个领域中训练出来的模型, 通过更新和复用该模型参数和模型架构, 使其能够在新领域中发挥优秀的性能。

在本实验中, 将 VGG16 网络模型的全部卷积层进行迁移, 用作特征提取器, 并把卷积层的初始学习率设置为 5×10^{-3} , 全连接层的初始学习率设置为卷积层学习率 10 倍。这样设置能使得网络在训练的时候, 通过反向传播更新卷积层的参数, 使得卷积层能够适应新的特征提取任务; 全连接层采用更大的学习率, 使全连接层能够快速收敛。最后通过动态学习率调整策略, 使得学习率随训练轮次的增加而逐步降低, 让模型在训练过程中

学到更多的特征, 提升模型性能。

在本小节中, 为了验证微调的实验性能, 分别进行了 2 组实验。第 1 种是冻结预先训练好的 VGG16 网络的卷积层部分, 仅对全连接层以 10 倍初始学习率进行训练; 第 2 种是按照上述实验设置对网络进行训练, 2 组实验同时使用动态调整学习率, 实验结果如表 5 所示。由表可知, 经过卷积层的微调后的模型在验证精度上较未使用微调技术的 VGG16 模型的精度提升了 2.16%, 说明经过微调后的模型具有更强大的学习能力, 能够适应新的任务并且可以学习到更多的图像特征。

经过微调后的桥梁病害检测模型训练过程的损失曲线和准确率曲线如图 5 所示。不难看出, 通过迁移学习和微调技术, 模型能够在很短的时间内进行收敛, 并达到足够高的准确率, 足以说明

本文方法的有效性。

表5 微调结果对比

Table 5 Comparison of fine-tuning results

模型	验证精度/%	各类病害识别精度/%		
		泛碱	露筋	裂缝
VGG16_lr_schedule	96.70	95.47	95.29	99.25
本文方法	98.86	98.49	98.04	100

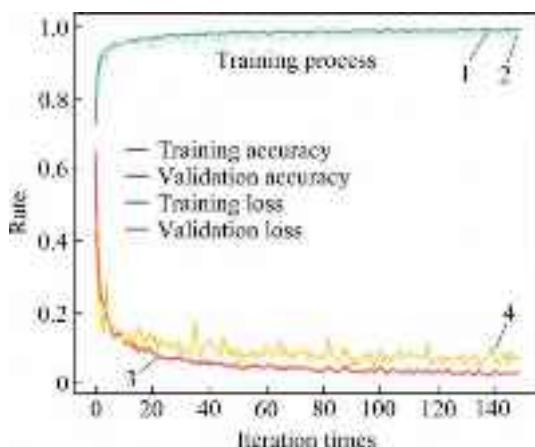


图5 桥梁病害检测模型损失曲线和准确率曲线

Fig. 5 Loss curve and accuracy curve of the bridge disease detection model

3.5 实验结果对比

依据数据集的划分，结合已训练好的网络模型与其他主流模型，以及复现文献[27](采用预训练 AlexNet 模型)中的模型在验证集上进行对比实验证，结果如表6所示。由表6可知，本文方法的实验效果较所有主流模型的实验效果都要好，其中较标准 VGG16 模型精度提升了 10.68%，较标准 ResNet50 模型准确率提高了 3.82%。另外，在验证集数量足够的情况下，本文建立的模型在每种病害类别上的识别准确率均高于其他模型，并取得了很高的准确率，分别为：泛碱 98.49%，露筋 98.04%，裂缝 100%。在作者团队的实验中，裂缝病害的检测准确率能达到 100% 的原因是由于迁移的 VGG16 卷积层具有强大的特征提取能力，再加上裂缝数据集的病害特征与另外 2 种病害特征相比单一简单，故能达到如此高的准确率。标准 VGG19 与标准 VGG16 相比精度下降，说明未经优化的标准模型网络层数越深，模型所学习到的噪音也越多，越容易过拟合，影响模型最后的判断。标准 ResNet18 和 ResNet50 模型的验证准确率达到

了 93.14% 和 95.04%，说明迁移学习的运用，能有效地提取桥梁表观病害的特征。使用动态学习率调整策略的 VGG16 模型，与原版的 VGG16 模型相比，准确率提高了 8.52%，这说明本研究所采用的动态学习率调整能够使得网络学习到更多的特征，有效地提高了模型的准确率。

表6 主流模型在验证集上的实验效果

Table 6 Experimental result of mainstream models on validation sets

算法模型	验证精度/%	各类病害识别精度/%		
		泛碱	露筋	裂缝
ResNet18	93.14	89.06	91.37	98.88
Resnet50	95.04	93.58	92.16	99.25
VGG19	86.66	82.26	82.75	94.76
VGG16	88.18	88.30	77.65	98.13
VGG16_lr_schedule	96.70	95.47	95.29	99.25
文献[27]	95.17	94.34	91.76	99.25
本文方法	98.86	98.49	98.04	100

通过上述对比实验所知，本文所采用的微调卷积层参数以及所采用的动态学习率调整能够有效抑制模型的过拟合，使得模型能够适应新任务，可以学习到桥梁表观病害特征，且具有很高的准确率。图6所示为各模型在验证阶段模型精度变化曲线。从图中可以看出，本文建立的模型在训练的开始阶段能够快速收敛，并且能够快速达到相对高的准确率，并在接下来的训练验证阶段始终领先于其他模型。并且在模型的训练验证阶段，本文的模型在验证集上的准确率的震荡幅度均小于其他模型方法，具有很高的鲁棒性，相较于其他模型具有一定的优势。图中 VGG19 模型效果最差，说明随着网络层数增加，网络出现了过拟合，模型陷入了局部最优点，导致模型在一定区域内反复震荡，无法跳出来。

另外本研究采用未经任何处理的实拍图片进行实验测试，每张图片的分辨率在 1 200 万以上，并且图片中包含多种噪声和复杂背景。经过测试，本文所提出的模型比复现的文献[27](文献[27]采取的测试策略是挑选经过裁剪的未包含噪声和复杂背景的图片)的方法测试准确率提升了 10%，说明该方法可用于实际工程应用检测，测试结果如表7 所示。




图6 各个模型验证过程中精度变化

Fig. 6 Variation of accuracy in the process of model validation

表7 含有噪声的图片比对结果

Table 7 Comparison results of test pictures with noise

算法模型	测试集 数量/张	测试精 度/%	各类病害识别精度/%		
			泛碱	露筋	裂缝
文献[27]	80	78.33	83.75	62.50	88.75
本文方法	80	88.33	96.25	80.00	88.75

4 结论

1) 提出了基于迁移学习的桥梁表观病害检测方法。结合迁移学习策略, 将VGG16模型的卷积层用作特征提取器以及对全连接层进行修改, 采用预训练VGG16模型参数对其进行初始化, 并在训练阶段将学习率动态调整策略和微调技术应用于卷积层和全连接层的参数微调整, 使其适用于桥梁病害检测任务。

2) 所提出的方法模型相较于其他主流模型, 在精度上有较大的提升, 在验证集上相较于原有的VGG16模型在精度上提升了10.68%, 并且在含有含多种噪声和复杂背景的实拍图片数据集上准确率达到了88.33%。该模型具有很高精度的桥梁病害识别率, 能够准确识别复杂背景下的桥梁表观病害特征, 可用于在役桥梁表观病害识别。

3) 在后续的进一步研究中, 针对采集到的含有噪声、复杂环境因素影响的数据集, 考虑采用注意力机制来提升病害识别准确率。该机制能将关注点定位在图像中的病害特征上, 以达到进一

步提升病害识别效果的目的。

参考文献:

- [1] 贺拴海, 赵祥模, 马建, 等. 公路桥粱检测及评价技术综述[J]. 中国公路学报, 2017, 30(11): 63–80.
HE Shuanhai, ZHAO Xiangmo, MA Jian, et al. Review of highway bridge inspection and condition assessment [J]. China Journal of Highway and Transport, 2017, 30(11): 63–80.
- [2] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84–90.
- [3] DEVRIES P M R, VIÉGAS F, WATTENBERG M, et al. Deep learning of aftershock patterns following large earthquakes[J]. Nature, 2018, 560(7720): 632–634.
- [4] 杨建喜, 张利凯, 李韧, 等. 联合卷积与长短记忆神经网络的桥梁结构损伤识别研究[J]. 铁道科学与工程学报, 2020, 17(8): 1893–1902.
YANG Jianxi, ZHANG Likai, LI Ren, et al. Research on bridge structural damage detection based on convolutional and long short-term memory neural networks[J]. Journal of Railway Science and Engineering, 2020, 17(8): 1893–1902.
- [5] YEUM C M, CHOI J, DYKE S J. Automated region-of-interest localization and classification for vision-based visual assessment of civil infrastructure[J]. Structural Health Monitoring, 2019, 18(3): 675–689.
- [6] CHA Y J, CHOI W, BÜYÜKÖZTÜRK O. Deep learning-based crack damage detection using convolutional neural networks[J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32(5): 361–378.
- [7] HUANG Hongwei, LI Qingtong, ZHANG Dongming. Deep learning based image recognition for crack and leakage defects of metro shield tunnel[J]. Tunnelling and Underground Space Technology, 2018, 77: 166–176.
- [8] 沙爱民, 童峥, 高杰. 基于卷积神经网络的路表病害识别与测量[J]. 中国公路学报, 2018, 31(1): 1–10.
SHA Aimin, TONG Zheng, GAO Jie. Recognition and measurement of pavement disasters based on convolutional neural networks[J]. China Journal of Highway and Transport, 2018, 31(1): 1–10.
- [9] 哈纳提·吐尔森哈力, 林杭. 融合自注意力机制与深度学习的混凝土表面裂隙智能识别[J]. 铁道科学与工程

- 学报, 2021, 18(4): 844–852.
- HANAT Tursenhalı, LIN Hang. Intelligent identification of cracks on concrete surface combining self-attention mechanism and deep learning[J]. Journal of Railway Science and Engineering, 2021, 18(4): 844–852.
- [10] 杨杰文, 章光, 陈西江, 等. 基于深度学习的较复杂背景下桥梁裂缝检测[J]. 铁道科学与工程学报, 2020, 17(11): 2722–2728.
- YANG Jiewen, ZHANG Guang, CHEN Xijiang, et al. Research on bridge crack detection based on deep learning under complex background[J]. Journal of Railway Science and Engineering, 2020, 17(11): 2722 – 2728.
- [11] GAO Xinwen, JIAN Ming, HU Min, et al. Faster multi-defect detection system in shield tunnel using combination of FCN and faster RCNN[J]. Advances in Structural Engineering, 2019, 22(13): 2907–2921.
- [12] ZHANG A, WANG K C P, FEI Yue, et al. Automated pixel-level pavement crack detection on 3D asphalt surfaces with a recurrent neural network[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34(3): 213–229.
- [13] XU Yang, WEI Shiyin, BAO Yuequan, et al. Automatic seismic damage identification of reinforced concrete columns from images by a region-based deep convolutional neural network[J]. Structural Control and Health Monitoring, 2019, 26(3): e2313.
- [14] ZHUANG Fuzhen, QI Zhiyuan, DUAN Keyu, et al. A comprehensive survey on transfer learning[J]. Proceedings of the IEEE, 2021, 109(1): 43–76.
- [15] PAN S J, YANG Qiang. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345–1359.
- [16] YANG Qiang, ZHANG Yu, DAI Wenyuan, et al. Transfer learning[M]. Cambridge: Cambridge University Press, 2020.
- [17] DENG Jia, DONG Wei, SOCHER R, et al. ImageNet: a large-scale hierarchical image database[C]// 2009 IEEE Conference on Computer Vision and Pattern Recognition. June 20–25, 2009, Miami, FL, USA. IEEE, 2009: 248–255.
- [18] NARAZAKI Y, HOSKERE V, HOANG T A, et al. Automated bridge component recognition using video data[J]. arXiv preprint arXiv:1806.06820, 2018.
- [19] LIANG Xiao. Image-based post-disaster inspection of reinforced concrete bridge systems using deep learning with Bayesian optimization[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34(5): 415–430.
- [20] DUNG C V, SEKIYA H, HIRANO S, et al. A vision-based method for crack detection in gusset plate welded joints of steel bridges using deep convolutional neural networks[J]. Automation in Construction, 2019, 102: 217–229.
- [21] KIM B, CHO S. Automated vision-based detection of cracks on concrete surfaces using a deep learning technique[J]. Sensors, 2018, 18(10): 3452.
- [22] YANG Xincong, LI Heng, YU Yantao, et al. Automatic pixel-level crack detection and measurement using fully convolutional network[J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33(12): 1090–1109.
- [23] DUNG C V, ANH L D. Autonomous concrete crack detection using deep fully convolutional neural network [J]. Automation in Construction, 2019, 99: 52–58.
- [24] VALIKHANI A, JABERI JAHROMI A, POUYANFAR S, et al. Machine learning and image processing approaches for estimating concrete surface roughness using basic cameras[J]. Computer-Aided Civil and Infrastructure Engineering, 2021, 36(2): 213–226.
- [25] CAO Xiaoping, LI Tao, BAI Jiawei, et al. Identification and classification of surface cracks on concrete members based on image processing[J]. Traitement Du Signal, 2020, 37(3): 519–525.
- [26] NI Futao, ZHANG Jian, CHEN Zhiqiang. Zernike-moment measurement of thin-crack width in images enabled by dual-scale deep learning[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34(5): 367–384.
- [27] 韩晓健, 赵志成, 沈泽江. 卷积神经网络在桥梁结构表面病害检测中的应用研究[J]. 结构工程师, 2019, 35(2): 106–111.
- HAN Xiaojian, ZHAO Zhicheng, SHEN Zejiang. Detect diseases on the surface of bridge structures by convolution neural network[J]. Structural Engineers, 2019, 35(2): 106–111.
- [28] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[M]// Domain Adaptation in Computer Vision Applications. Cham: Springer International Press, 2017: 189–209.

(编辑 涂鹏)