

文章编号:1001-7372(2024)02-0016-13

桥梁裂缝智能识别与监测方法研究

岳清瑞^{1,2,3}, 徐 刚^{2,3}, 刘晓刚^{*1,3}

(1. 北京科技大学 土木与资源工程学院, 北京 100083; 2. 西安建筑科技大学 土木工程学院, 陕西 西安 710055; 3. 北京科技大学 城镇化与城市安全研究院, 北京 100083)

摘要:当前,裂缝识别与监测一直是桥梁结构健康监测的重要研究内容。在桥梁结构现场检测与监测中,传统的裂缝识别与监测技术尚不足以满足实际工程的时效性和精确性需求,尤其是裂缝监测技术。基于深度学习的裂缝图像识别极大提升了裂缝检测的效率和精度,但目前仅能获得特定时刻的裂缝信息,缺乏对裂缝产生和演化过程的监测能力,而这些信息对混凝土结构服役安全量化和科学评价具有重要意义。鉴于此,对基于深度学习的裂缝识别与监测方法进行了系统研究,分析和讨论了裂缝数据集构建基准,改进优化了裂缝目标检测和语义分割算法,提出一种多任务集成一体化实时识别算法,并建立了该模型推理效果评价方法,优化了裂缝参数计算方法,最终形成了裂缝识别及动态扩展自动化实时监测方法。结果表明:所提出的裂缝智能识别与监测方法可以对新裂缝的产生和既有裂缝的全局演化实现良好追踪,监测数据可以为桥梁结构当前服役性能的科学量化评估提供支撑。

关键词:桥梁工程;桥梁结构;智能识别与监测;混凝土裂缝;深度学习;裂缝参数;推理效果
中图分类号:U446.3 **文献标志码:**A

Crack Intelligent Recognition and Bridge Monitoring Methods

YUE Qing-rui^{1,2,3}, XU Gang^{2,3}, LIU Xiao-gang^{*1,3}

(1. School of Civil and Resource Engineering, University of Science and Technology Beijing, Beijing 100083, China; 2. College of Civil Engineering, Xi'an University of Architecture and Technology, Xi'an 710055, Shaanxi, China; 3. Research Institute of Urbanization and Urban Safety, University of Science and Technology Beijing, Beijing 100083, China)

Abstract: Recognition and monitoring of cracks is an important part of the current research on the structural health monitoring of bridges. In the field of inspection and monitoring of bridge structures, traditional crack recognition and monitoring techniques, particularly crack monitoring techniques, hardly meet the timeliness and accuracy requirements of practical projects. Crack recognition based on deep learning has greatly improved the efficiency and accuracy of crack detection; however, it can only obtain crack information at a specific moment, and the ability to monitor the process of crack generation and evolution, which is crucial for a more reasonable evaluation and safety quantification of concrete structures, is lacking. In view of this, a systematic study of crack recognition and monitoring methods based on deep learning was performed. In this study, we analyze and discuss the construction benchmark of a crack dataset,

收稿日期:2023-03-20

基金项目:国家自然科学基金重大项目(52192663,51890903);北京科技新星计划项目(Z201100006820044)

作者简介:岳清瑞(1962-),男,黑龙江齐齐哈尔人,中国工程院院士,E-mail:yueqr@vip.163.com。

*通讯作者:刘晓刚(1986-),男,山东烟台人,教授,博士研究生导师,工学博士,E-mail:liuxiaogang@ustb.edu.cn。

improve and optimize the crack detection and semantic segmentation algorithms, propose a real-time recognition algorithm for multitask integration, establish an evaluation method for the model inference effect, and optimize the calculation method of crack parameters, ultimately forming crack recognition and automatic real-time monitoring algorithms for crack dynamic expansion. The results show that the proposed method for intelligent recognition and monitoring of cracks can effectively track the generation of new cracks and the global evolution of existing cracks, and the monitoring data can provide support for a reasonable and quantitative assessment of the current service performance of bridge structures.

Keywords: bridge engineering; bridge structure; intelligent recognition and monitoring; concrete crack; deep learning; crack parameters; inference effect

Received 20 Mar. 2023

Funding: Major Program of National Natural Science Foundation of China (52192663, 51890903); Beijing Nova Programme (Z201100006820044)

*Corresponding author. *E-mail address:* liuxiaogang@ustb.edu.cn.

<https://doi.org/10.19721/j.cnki.1001-7372.2024.02.002>

0 引言

改革开放40余年,中国交通基础设施建设高速发展,保有量不断攀升,尤其是近20年以来,交通基础设施呈现出提速发展和集中建设的特点^[1];但随之而来的服役安全保障却面临着总量巨大和强度集中的压力。据最新的行业统计数据显示,中国桥梁数量已超80万座,其中服役时间超过30年的桥梁达到25万座。桥梁结构在外部荷载、环境腐蚀、材料老化及突发事件灾害等因素耦合作用下不可避免地会出现裂缝。过宽的裂缝会导致混凝土结构保护层对内部钢筋的保护失效,引起钢筋锈蚀,进而诱发其他形式的裂缝、变形甚至破坏;而快速发展的受力裂缝更是桥梁结构承载失效和倒塌的先兆。因此,裂缝与结构服役性能之间势必存在一种内在受力关联关系。换言之,裂缝可以作为表征桥梁结构当前服役性能和安全性的重要指标,完整的裂缝信息更是科学评价桥梁结构当前服役性能的重要依据。

然而,在桥梁结构现场检测中,以人工检测为主的裂缝识别方法不仅费时费力,而且还存在测不准、记不全、效率低等缺点^[2],传统的裂缝识别技术尚不足以满足实际工程的时效性和准确性需求。随着计算机硬件能力与智能算法的高速发展,基于深度学习的裂缝识别算法得到了广泛的研究与应用^[3-4]。总体而言,基于深度学习的识别算法按照任务类别可以分为分类、目标检测和图像分割。近年来,随着层数更深的神经网络陆续被提出,图像分类的精度

越来越高,目前使用较多的神经网络主要有 AlexNet^[5]、GoogLeNet^[6]、VGGNet^[7]和 ResNet^[8]等。而目标检测在图像分类算法基础上更进一步,不仅可以判断图像类别,而且还能利用边界框来定位目标实例。在目标检测算法中,当前主要以单阶段神经网络和两阶段神经网络为主。前者主要以YOLO系列(You Only Look Once)^[9-11]、SSD(Single Shot Multibox Detector)^[12]及 RetinaNet^[13]等算法为代表,后者主要以基于区域的卷积神经网络R-CNN(Region-based Convolutional Neural Network)系列^[14-15]和 SPP-Net^[16]等算法为代表。与两阶段目标检测算法相比,单阶段目标检测算法不需要对预选框进行微调和背景剔除操作,而是直接输出结果,即只执行一次前馈网络计算。因此,单阶段目标检测算法的计算速度较快,可以实现实时检测目标对象,但其检测精度通常低于两阶段方法。

虽然目标检测算法能够高效识别裂缝,但无法直接在像素级层面提取裂缝,还需要结合阈值算法、边缘算法等图像处理技术^[17-18]才能完成像素级的裂缝提取。相比传统的图像分割技术,基于深度学习的图像分割算法^[19-20]能够直接从原始图像中端到端提取裂缝。当前,基于深度学习的语义分割算法主要是采用全卷积神经网络(FCN)^[21]进行像素级的裂缝图像分割。进一步地,基于FCN的裂缝分割研究主要集中在改进基于DeepLab系列^[22]、U-Net系列^[23]、Mask R-CNN^[24]、BiSeNet系列^[25]、PSPNet^[26]、SegNet^[27]和 RefineNet^[28]等算法基础上。然而,这

些算法大多是为解决某一特定问题而设计的,功能相对单一,即使以 Mask R-CNN 为代表的算法可以实现双任务,但由于它是在 R-CNN 两阶段目标检测算法基础上增加了分割算法 FCN,计算效率低,因此无法实现实时性检测。此外,也有少量研究人员^[29-30]将目标检测算法与分割算法进行简单组合,分多阶段完成,即先利用目标检测算法对裂缝进行检测,然后再对检测出的裂缝进行深度学习语义分割或者数字图像处理分割。但这些方法无法实现高精度、实时性检测和分割裂缝,也未能形成通用的基础方法。

另外,裂缝的高效识别与动态扩展监测,也是获得全时的裂缝详细信息、提供更加完整的桥梁结构服役信息以及支撑更加科学的桥梁结构服役安全性评价的必要手段。然而,当前常用的裂缝监测方法主要有基于长标距光纤光栅的混凝土裂缝监测方法^[31-32]、基于柔性导电涂料的混凝土裂缝监测方法^[33]、基于声发射的混凝土裂缝监测方法^[34]以及基于摄影测量技术的裂缝监测方法^[35]等,这类方法一方面存在设备部署相对复杂、造价高、易老化失效等问题,另一方面也仅能够实现对特定某一裂缝的宽度监测。如前所述,虽然基于深度学习的裂缝图像识别极大提升了裂缝检测的效率和精度,但目前仅能获得特定时刻的裂缝信息,缺乏对裂缝产生和演化过程的监测能力,而这些信息对混凝土结构服役安全量化和科学评价具有重要意义。Kong 等^[18]提出了基于裂缝骨架线形状上下文匹配的监测方法,但该方法不仅需要对所有裂缝图像进行滤波降噪、阈值处理及边缘检测等系列的图像处理操作,而且还需要提取裂缝骨架线进行上下文匹配。由于骨架线细化算法在裂缝端部和形状突变的部位引起的误差相对较大,因此骨架线上下文匹配的阈值难以有效设定,方法操作复杂,效率低,无法实现实时监测和预警。

因此,本文旨在解决现有算法在裂缝检测、分割及监测等技术上存在的精度与效率不平衡问题,从数据集、裂缝识别算法、模型推理、裂缝参数量化及裂缝监测等多个视角系统地开展桥梁裂缝智能识别与监测方法的研究。本文的研究思路包括以下几个方面:首先,利用目标检测算法和语义分割算法分别探究裂缝目标检测数据集增强方法和裂缝语义分割数据集基准,以建立裂缝识别与监测的基础模型;其次,优化并改进基于深度学习的裂缝目标检测和语义分割算法,开发一种集裂缝图像分类、定位和语义

分割于一体的集成模型,并利用分类与定位结果生成的裂缝目标检测定位图和语义分割连通域进行校核去噪;同时,提出一种基于裂缝像素所在行或列的精细化定量评价方法,用于评估模型推理结果;然后,借鉴有限单元法的基本思想,研发一种基于微元法的裂缝参数量化计算方法,将模型输出的裂缝二值化掩膜转化为裂缝参数信息;最后,在上述研究基础上,建立一种基于改进优化目标检测算法的裂缝动态扩展实时监测体系,该监测体系采用相较于现有的基于裂缝骨架线形状上下文匹配方法更为高效的裂缝扩展判断基准,并经试验验证其有效性。

1 数据集构建基准

数据集按任务类别可以分为 3 类,分别为分类、目标检测和分割数据集。从目前文献中已开源的裂缝相关数据库^[36-39]中可以看出,数据集样本以路面场景为主,并且图像分类和目标检测任务居多,而桥梁混凝土裂缝图像分割样本较少,并且图像标注质量参差不齐。更重要的是,目前缺乏一种关于数据集样本数量和标注质量的基准。

由于图像分类和目标检测样本标注简单,大多数研究人员标注的裂缝样本数量在千张级别以上,然后再利用数据增强方法进行扩充样本,数据增强方式主要包括旋转、翻转、平移、亮度变换及增加高斯噪声等。考虑到工程中桥梁裂缝所处的实际环境,采用一种基于裂缝周围局部区域增加高斯噪声或亮度变换的图像增强方法对样本进行扩充。为验证该方法的有效性,本文标注了 2 360 张分辨率为 640 像素×640 像素的裂缝图像,部分样本图像如图 1 所示,其中涵盖了多种环境干扰因素,如不同像素宽度的裂缝,混凝土表面的麻面、孔洞、缺损等多种噪点,与裂缝颜色相同的背景以及与裂缝形状相似的细线、铁丝、标记等,并包含有交叉裂缝及多条并行裂缝等。这些特征与桥梁裂缝所处的现场实际情况基本接近。然后,将训练集与验证集的样本按照 8:2 的比例随机划分,并对训练集中的样本分别进行翻转、旋转、亮度变换、裂缝局部区域增添高斯噪声与亮度变换处理,如图 2 所示。为便于区分差异性,将同类别扩充的样本合并为一组,共分为 3 组,即翻转与旋转、亮度变换及裂缝局部区域增添高斯噪声与亮度变换。以 YOLOv7 目标检测算法^[11]为例,表 1 分别比较了这几种样本增强方法对模型性能指标的提幅值。研究结果表明:本文提出的裂缝样本增强方法在 mAP@0.5 性能指标上与翻转与旋




图 1 部分裂缝样本图像

Fig. 1 Images of Some Crack Samples

转方法基本相当,相比亮度变换方法提高了3.54%,同时也比增强前提高了 3.58%,增强效果显著。

在语义分割数据集方面,由于裂缝样本标注成

本较高,大多数研究者标注的裂缝样本数量在几十或上百张,标注质量也参差不齐。更多的研究工作集中在算法改进上,而忽略了数据集样本数量和标注质量对模型性能的影响。针对此问题,本文在裂缝图像分割样本标注时,首先采用一种可以量化的低质量与高质量标注方法。低质量标注的裂缝样本单侧偏差一般控制在 0.5~2 像素之间,高质量标注的裂缝样本单侧偏差控制在 0.5 像素以内。以图 3 所示的裂缝图像为例,图像分辨率尺寸为 640 像素×640 像素,对有图像标注经验的工程技术人员而言,低质量与高质量标注时长分别约为 2.33、13.5 min。其次,以高质量标注的样本数量、低质量与高质量标注的样本混合比例等变量参数组成多种数据集子集,分别探讨了高质量标注的样本数量、低质量标注的样本数量及低质量与高质量标注的样本混合比例对模型的性能影响,并形成了一个可以量化的基准方法。




图 2 裂缝样本增强方法

Fig. 2 Enhancement Methods for Crack Samples

表 1 裂缝样本增强方法对比结果

Table 1 Comparison of Enhancement Methods for Crack Samples

样本增强方法	训练集样本数量	验证集样本数量	mAP@0.5/%
无	1 888	472	77.99
翻转与旋转	5 664	472	81.57
亮度变换	5 664	472	78.03
裂缝局部区域增添高斯噪声与亮度变换	5 664	472	81.57

以 DeepLabv3+ 分割模型^[22]为例,采用 Resnet-101^[40]网络作为其主干网络,模型在不同裂缝数据集子集训练下的性能指标平均交并比 mIoU 曲线

如图 4 所示。结果表明:当高质量标注的样本数量低于 1 722 张时,模型 mIoU 值呈指数型增长,超过 1 722 张后模型 mIoU 值基本不变;在 2 360 张裂缝图像的数据集下,低质量标注的裂缝样本替代率达到 60%时,模型 mIoU 值仅降低 0.44%,而样本标注时间可以节约近 422 h;以训练集 400 张高质量标注的裂缝图像样本为基准,低、高质量标注样本混合比例与模型 mIoU 值呈指数型关系,低质量标注样本对模型 mIoU 损失值的影响随着样本数量的增大先迅速上升,后缓慢下降,最后趋于平缓,并且当低、高质量标注样本混合比例超过 1.45 时,模型 mIoU 损失值能控制在 0.005 范围内,样本标注时间也可




图3 裂缝样本标注过程

Fig. 3 Process of Labelling Crack Samples

以节约超过 216 h。同样地,分别以 DRN^[41]、Xception^[42] 及 Mobilenetv2^[43] 网络作为 DeepLabv3+ 分割模型的主干网络进行上述分析,也得到了类似的结论。因此,基于上述基准方法,通过选择适当的数据子集并对模型算法进行优化,可以进一步提高模型精度同时降低模型训练时间,提高效率。

2 裂缝智能识别算法

2.1 裂缝目标检测算法

在基于深度学习的目标检测算法中,由于单阶段目标检测算法具有较高的推理速度,近年来研究者也提出了多种单阶段目标检测算法。尤其在 2022 年,Joher 等^[9]将 YOLOv5 目标检测算法升级迭代至 6.2 版本,美团公司技术团队 Li 等^[10]提出了 YOLOv6 目标检测算法,与此同时,Wang 等^[11]也提出了 YOLOv7 目标检测算法,进而掀起了单阶段目标检测算法研究的热潮。

在桥梁裂缝识别场景中,当前更多的是将相机搭载在移动设备上实时检测,其所需要的推理速度要远低于其他工业应用场景,即只要模型的推理速度大于相机视频捕获图像的速度,则可以保证每个捕获的图像都可以被处理。因此,本文基于最新的 YOLOv7 目标检测算法进行改进优化,在保证推理速度满足桥梁裂缝实时识别与监测的要求下尽可能地提高裂缝检测精度。为此,本文在 YOLOv7 目标检测算法的主干网络中引入了一种全局注意力机制^[44],该机制主要通过减少信息缩减和放大全局交互表示来提高深度神经网络的性能,其结构如图 5 所示。首先,将该全局注意力机制嵌入到 YOLOv7 模型的第 12 层位置,可聚焦通道和空间信息,以提高主干网络提取裂缝特征的能力。随后,在模型的第 63 层和 76 层位置继续引入该机制,以保留通道和空间方面的信息,进一步提高深度神经网络的性能。

表 2 比较了本文改进的 YOLOv7 算法与其他几种常见的单阶段目标检测算法的性能。结果表明:本文改进的 YOLOv7 算法在混凝土裂缝数据集

中训练的性能指标最高。在精确度方面,改进后的 YOLOv7 算法比 YOLOv5(6.2 版本)、YOLOv6 及 YOLOv7 算法分别提高 5.34%、3.96% 和 3.17%, mAP@0.5 的指标也分别提高 1.72%、0.66% 和 0.57%。在推理速度方面,虽然改进后的 YOLOv7 模型的推理速度最低,但 44 帧·s⁻¹ 的模型推理速度也大于视频相机捕获图像的速度,即可以保证每个捕获的图像都可以被处理,能满足桥梁裂缝实时检测与监测的要求。

另外,表 3 列出了改进前后 YOLOv7 模型在裂缝图像目标检测上的对比结果。这些图像中存在各种与实际环境接近的噪声,比如不同的光照背景、表观痕迹、铁丝、细线和粘贴物等。对比结果表明,改进前的 YOLOv7 模型存在裂缝局部区域重复检测以及将混凝土表观痕迹和细线误检测为裂缝的情况。然而,改进优化后的 YOLOv7 模型能够显著提升模型的降噪能力,从而从另一方面提高了检测精度。

2.2 裂缝语义分割算法

裂缝图像分割算法所选的模型其分割精度是最重要的,裂缝分割效果直接影响到裂缝参数的量化。因此,基于 Meng 等^[30]对比分析得到的 DeepLabv3+、DenseNet121-FCN、SegNet、DlinkNet50 及 BiSeNetV2 等几种流行的分割算法性能的研究结果,本文选择性能较为优异的、且具有编码和解码结构的 DeepLabv3+ 分割模型^[22]作为基准模型,在解码结构中高级特征图与浅层特征图级联融合后引入一种改进的注意力机制进一步聚焦优化后特征图的裂缝特征信息,降低非裂缝特征信息的关注度,如图 6 所示,并利用迁移学习策略将预训练网络模型的权重迁移到主干网络中。

分别以 Resnet-101、Xception、DRN 及 Mobilenetv2 网络作为 DeepLabv3+ 分割模型的主干网络,并将这些模型与 Swin Transformer 分割模型^[45]和 SegFormer 分割模型^[46]以及本文改进的 DeepLabv3+ 分割模型进行同一数据集下的训练,各模型的性能指标结果如表 4 所示。结果表明:本




图 4 不同数据集子集训练下的 DeepLabv3+ 模型的性能指标曲线

Fig. 4 Performance Metrics Curves for DeepLabv3+ Model Trained on Different Sub-datasets

文改进的 DeepLabv3+ 分割模型在混凝土裂缝数据集中训练的性能指标最高,相比于以 Resnet-101、Xception、DRN 及 Mobilenetv 2 为主干网络的

表 2 与流行的目标检测算法对比

Table 2 Comparison with Popular Crack Detection Algorithms

方法	裂缝检测评估指标				参数量/M
	精确度/%	mAP@0.5/%	mAP@0.5:0.95/%	推理速度/(帧·s ⁻¹)	
YOLOv5(6.2 版本)	78.22	82.98	68.94	156	46.11
YOLOv6	79.60	84.04	69.32	240	44.19
YOLOv7	80.39	84.13	70.63	135	37.20
本文改进的 YOLOv7	83.56	84.70	71.69	44	47.24
提高幅度	+5.34	+1.72	+2.75	-	-

表 3 改进前与改进后的 YOLOv7 模型的裂缝图像检测结果比较

Table 3 Comparison of Crack Image Detection Results Before and After Improvement for YOLOv7 Model

编号	原图	裂缝图像目标检测真实值	目标检测模型输出的结果	
			YOLOv7 模型	改进后的 YOLOv7 模型
1				
2				
3				

表 4 裂缝分割算法对比

Table 4 Comparison of Crack Segmentation Algorithms

方法	裂缝分割评估指标			
	像素精确度/%	平均交并比/%	加权频率交并比/%	推理时间/s
DeepLabv3+(Resnet-101)	99.76	95.05	99.52	3.40
DeepLabv3+(Xception)	99.52	90.58	99.07	3.36
DeepLabv3+(DRN)	99.75	94.97	99.51	3.32
DeepLabv3+(Mobilenetv2)	99.72	94.29	99.45	3.62
Swin Transformer	99.75	94.93	-	2.63
SegFormer	99.69	93.66	-	5.83
本文改进的 DeepLabv3+	99.76	95.20	99.54	3.54
提高幅度	+0.24	+4.62	+0.47	-

DeepLabv3+ 分割模型、Swin Transformer 分割模型和 SegFormer 分割模型,改进的 DeepLabv3+ 分

割模型平均交并比分别提高了 0.15%、4.62%、0.23%、0.91%、0.27% 和 1.54%，而像素精确度和加权频率交并比略有提高，但幅度较小。这主要是由于分割模型在数据集中训练的指标已非常高，评估指标敏感性低。此外，模型推理时间也基本持平。

2.3 裂缝多任务集成算法

裂缝识别算法按任务类别可以分为分类、目标检测与图像分割，当前的相关算法大多是针对某类任务来实现的，功能相对单一。如今，随着裂缝识别应用场景的多样性和复杂性增强，单一任务模型已无法满足工程实际需求，尤其在数据量上涨、运算力提升及机器学习新算法出现的背景下，多元化的任务集成势必会迎来发展。

目前，虽然以 Mask R-CNN^[24] 为代表的算法可以实现目标检测与语义分割双任务目标，但由于它是在 R-CNN 两阶段算法基础上增加了分割算法 FCN，计算效率低，因此无法实现裂缝实时性检测和分割。此外，也有少量研究人员^[39-41] 将目标检测算法与分割算法进行简单组合，分多阶段完成，即首先利用目标检测算法对裂缝进行检测，然后对检测出的裂缝进行基于深度学习的语义分割或者基于数字图像处理的图像分割，最后得到分割后的裂缝二值化掩膜。虽然这些方法能将多任务目标一体化集成，但由于图像处理算法的局限性很难做到高精度、实时性识别裂缝，也未能形成普适性的通用方法。更重要的是，一旦前一步裂缝目标检测失败，

则后续就无法正确分割裂缝。

本文在第 2.1 节和 2.2 节的研究基础上，以单阶段目标检测算法为基础，构建了一个轻量级图像分割分支。首先，利用单阶段目标检测算法的主干网络进行提取裂缝特征，并将该特征信息分别传递给分类网络、回归网络和分割网络模块。各个网络分支模块分别输出分类结果、定位结果和分割结果。然后，利用分类与定位的结果生成裂缝目标检测定位图，并将该定位图与语义分割结果的连通域进行校核。通过校核子模块，只保留含有裂缝的连通域，以进一步提高裂缝分割的准确度和效率。与语义分割结果相比，分类和目标检测的误检概率较低，因此，该校核子模块利用语义分割输出预测结果的的所有连通域信息并与分类和定位输出预测裂缝定位图信息进行校核，当连通域和定位图的中心坐标、矩形框面积均相近时，将该连通域判定为裂缝；反之，则判定为噪声，并将判定为噪声的连通域删除，仅保留含裂缝的连通域。最终，该算法实现了裂缝图像高精度实时分类、检测和分割的多任务一体化集成目标，集成算法流程如图 7 所示。



图 5 全局注意力机制结构图
Fig. 5 Architecture of Global




图 6 改进的注意力机制
Fig. 6 Architecture of Improved Attention Mechanism




图 7 集成算法流程图

Fig. 7 Flowchart of Integration Algorithm

表 5 给出了该集成算法的性能评估指标。结果表明：本文提出的集成算法能够正确分类裂缝图像，裂缝检测的精确度和 $mAP@0.5$ 分别能达到 82.22% 和 83.32%，裂缝分割的平均交并比达到 94.63%，两者的推理时间均在毫秒量级，可以实现搭载移动设备进行桥梁裂缝图像实时分类、定位和分割多任务的目标。

4 裂缝参数计算方法

一旦裂缝被成功识别后,就可以利用相应算法获取裂缝参数。裂缝参数主要包括分布、宽度、长度、角度、间距等。近年来,研究者对裂缝宽度、长度的计算方法研究较多,而对裂缝分布、角度及间距的计算方法研究相对较少。其中,在裂缝宽度计算方面,刘宇飞等^[2]进行了系统综述,并对比分析了 4 类代表性算法的优点和劣势,即基于中心线的裂缝宽度法^[47-48]、基于边缘线最小距离的裂缝宽度法^[49]、局部平均裂缝宽度法^[50]及基于灰度值的裂缝宽度法^[51]。在裂缝长度计算方面,当前代表性的算法以以下 2 类为主:形态学细化算法^[52]和八连通-查表算法^[53]。具体实施时,首先利用这类算法获取裂缝骨架线,然后再依次计算相邻 2 个像素点之间的距离并求和,从而计算出裂缝长度,或者直接利用骨架线的像素之和计算裂缝长度。

然而,上述这些算法在实际应用中仍然存在一些不足,主要为以下几点:①裂缝宽度计算主要以整像素为主;②部分方法需要对裂缝体方向进行预处理,如旋转图像操作等;③传统的裂缝边缘线、骨架线细化算法误差较大,尤其在端部边缘部位、曲线突变部位计算误差显著;④算法原理简单但流程复杂;⑤计算参数种类少,未形成一套完整的裂缝参数计算方法。

本文结合有限单元法的基本思想,提出一种基于微元法的裂缝参数计算方法。该方法避免了采用传统骨架线等提取算法带来的误差,实现了亚像素级计算精度,并且形成了一套集裂缝分布、宽度、长度、角度及间距等参数于一体的计算方法,精度高,计算效率高。基于微元法的裂缝参数计算方法基本思路如下:

首先,将裂缝划分为多个微单元,然后再对微单元内的裂缝像素进行相应处理以得到不同参数计算结果。具体如下:①当对微单元内的所有裂缝像素求中心点坐标时,可以得到微单元分布,如图 10(a)所示;②遍历微单元的两侧边缘像素坐标后,分别对两侧边缘点进行双三次样条插值,然后再采用最小二乘法分别对插值后的亚像素边缘点进行拟合,得到拟合边缘直线,接着沿微单元中心点做 2 条拟合边缘直线的垂线,2 个垂足的欧式距离即为该微单元的裂缝宽度,如图 10(b)所示;③对微单元内的所有裂缝像素坐标进行最小二乘法拟合,得到拟合直线的斜率,由斜率即可得到该微单元的裂缝角度,如

图 10(c)所示;④以微单元内的所有裂缝像素坐标拟合得到的直线斜率,做一条经过微单元中心点的直线,该直线与微单元上下边界相交,2 个交点的欧式距离即为微单元的裂缝长度,如图 10(d)所示。最后,所有微单元的中心点连线轨迹即为整条裂缝的分布;搜索所有微单元的裂缝宽度,可得到最大裂缝宽度及其对应的位置;所有微单元的裂缝长度相加即为整条裂缝长度;所有微单元的裂缝角度求和取均值即可得到整条裂缝的角度;2 条裂缝的所有微单元在横坐标或纵坐标方向的坐标均值之差即为该 2 条裂缝的间距,如图 10(e)所示。

在钢筋混凝土构件加载试验中,在混凝土开裂表面上随机选取了 7 个测点位置进行测试,测点分布如图 11(a)所示。表 6 给出了基于微元法计算的裂缝宽度与实测裂缝宽度的比较结果,结果表明本文提出的裂缝宽度计算方法相对误差在 7% 以下。与文献[18]、[29]中所提出的计算方法相比,本文方法计算精度相对较高。以图 11(a)所示的裂缝图像为例,根据本文提出的裂缝参数计算方法,得到该图像的裂缝分布和角度可视化结果如图 11(b)所示,裂缝角度计算结果为 80.56° ,裂缝长度计算结果为 50.86 mm。本文提出的裂缝参数计算方法具有较高的准确度和可靠性,可以为工程实践中的裂缝检测与监测提供有力支持。

5 桥梁裂缝智能监测算法

裂缝监测是桥梁结构健康监测的一项重要内容。裂缝作为混凝土结构服役性能的重要表征指标,其产生、发展全过程信息的获取,是科学合理地量化评价桥梁结构当前服役性能的重要依据。随着新的智能算法的不断涌现,基于深度学习的裂缝识别算法可以为桥梁裂缝产生、扩展监测提供一种全新的研究途径,并且裂缝参数计算方法也能为监测过程中裂缝参数量化提供一个有效的手段。

在上述研究工作基础上,本文提出一种由改进的单阶段裂缝实时目标检测算法和裂缝扩展基准方法组成的监测方法,利用基于深度学习的分割算法对发生扩展的裂缝图像进行分割,并采用基于微元法的裂缝参数计算方法对裂缝各个参数的扩展程度进行计算,算法流程如图 12 所示。其中,裂缝扩展基准方法的主要思路如下:首先,当目标检测模型输出的当前帧图像的裂缝预测矩形框与上一帧图像的裂缝预测矩形框的像素尺寸面积不一致时,判断当前时刻裂缝发生了扩展。其次,当目标检测模型输

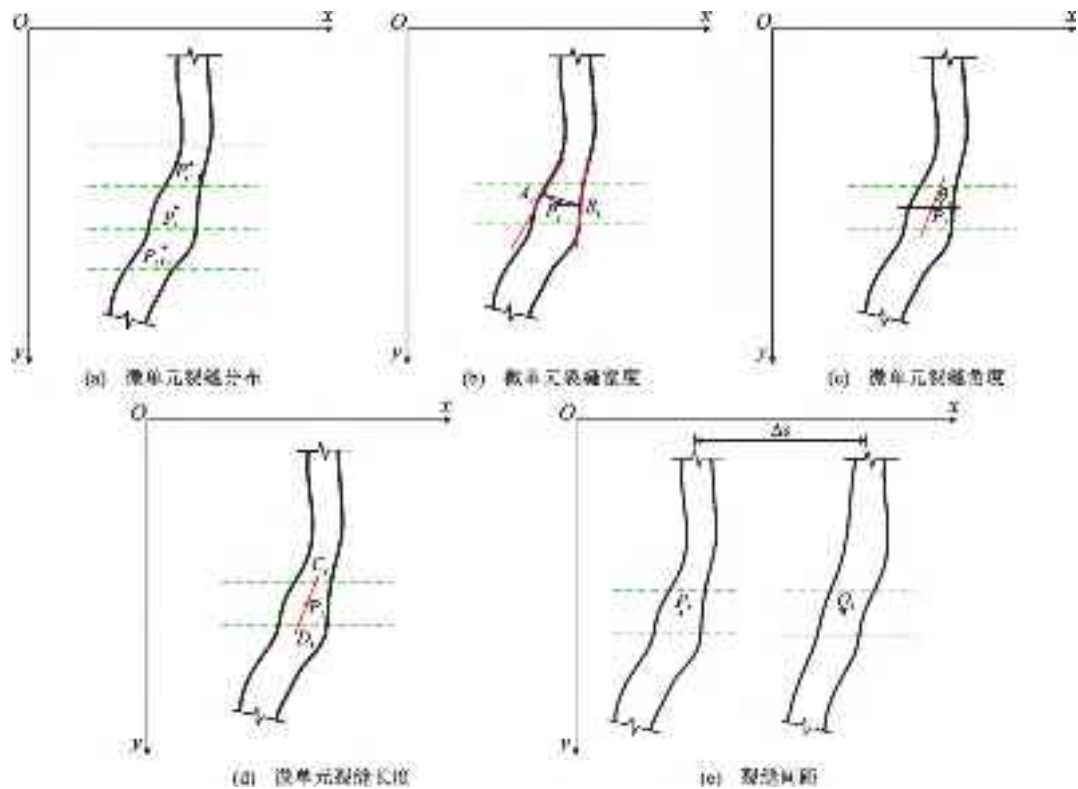


图 10 基于微元法的裂缝参数计算示意

Fig. 10 Schematic Diagram of Calculation of Crack Parameters Based on Micro-element Method




图 11 裂缝参数部分计算结果

Fig. 11 Partial Calculation Results of Cracking Parameters

表 6 裂缝宽度与实测数据的比较结果

Table 6 Results of the Crack Width and Comparison with Measured Data

序号	裂缝宽度/mm		绝对误差/mm	相对误差/%
	实测值	计算值		
1	0.88	0.872	-0.008	-0.91
2	0.79	0.797	0.007	0.89
3	0.71	0.738	0.028	3.94
4	0.71	0.706	-0.004	-0.56
5	0.49	0.503	0.013	2.65
6	0.44	0.467	0.027	6.14
7	0.31	0.300	-0.010	-3.23

出的当前帧图像的裂缝预测矩形框与上一帧图像的裂缝预测矩形框的像素尺寸面积基本不变时,再分




图 12 裂缝动态扩展流程图

Fig. 12 Flowchart of Crack Dynamic Expansion

别统计前后 2 帧图像中矩形框内的图像像素灰度值,绘制图像像素直方图,并做归一化处理,最后采用相关法计算 2 个直方图对应的图像的相似性。当相似性计算值小于 1 时,判断当前时刻裂缝发生了扩展;当相似性计算值等于或近似 1 时,判断当前时刻裂缝未发生扩展。对判定为未发生扩展的裂缝图像不进行图像分割和裂缝参数计算,因此,该监测方

法避免了因未扩展裂缝图像重复分割带来的效率低下,进而实现了更高效、更精准的裂缝动态扩展自动化实时监测。

采用本文第 2.1 节提出的改进的 YOLOv7 算法作为裂缝目标实时检测算法对图 13(a)钢筋混凝土构件加载过程中裂缝的出现、扩展进行实时监测,并利用裂缝图像分割算法和裂缝参数计算方法对扩展的裂缝进行量化。图 13 分别给出了钢筋混凝土试件在加载过程中某条裂缝的最大裂缝宽度、裂缝长度及裂缝角度变化的监测结果。由监测结果可知,基于本文提出的混凝土裂缝动态扩展监测方法,利用视频图像可以对混凝土结构新产生的裂缝进行实时识别,以及对既有裂缝的扩展进行实时监测,进而能得到裂缝各个部位的动态扩展程度。试验案例结果表明通过使用本文提出的裂缝动态扩展监测算法,裂缝监测的效率和精度得到了极大的提高,尤其是细小裂缝也能很好被监测到,该方法的可行性和有效性得到了验证。

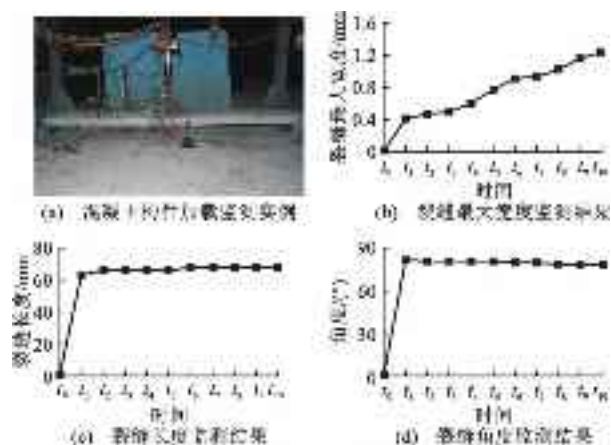


图 13 裂缝动态扩展结果

Fig. 13 Results of Crack Dynamic Expansion

6 结 语

本文针对现有裂缝识别算法在精度、速度及功能任务等方面存在的问题,从数据集、裂缝识别、模型推理、裂缝参数计算及裂缝动态扩展监测等方面,对基于深度学习的桥梁裂缝智能识别与监测方法进行了系统研究,主要研究结论如下:

(1) 基于裂缝目标检测数据集,提出了一种基于裂缝周围局部区域增加高斯噪声或亮度变换的数据集增强扩充方法,该方法对裂缝检测模型性能指标的提高幅度要高于现有方法。基于裂缝分割数据集,构建了高质量标注的样本数量、低质量与高质量标注的样本混合比例对裂缝分割模型性能影响的量

化参考模型,可以大幅节约数据集标注成本。

(2) 结合全局注意力机制原理对 YOLOv7 目标检测算法进行改进,改进后的 YOLOv7 目标检测算法精确度比 YOLOv5 (6.2 版本)、YOLOv6 及 YOLOv7 算法分别提高了 5.34%、3.96% 和 3.17%,mAP@0.5 指标也分别提高了 1.72%、0.66% 和 0.57%,降噪能力显著提升。

(3) 对 DeepLabv3+ 分割模型的解码结构部分引入了一种改进的注意力机制进一步聚焦优化后特征图的裂缝特征信息,改进后的 DeepLabv3+ 算法性能指标最高,相比以 Resnet-101、Xception、DRN 及 Mobilenetv2 为主干网络的 DeepLabv3+ 分割模型、Swin Transformer 分割模型和 SegFormer 分割模型,平均交并比分别提高 0.15%、4.62%、0.23%、0.91%、0.27% 和 1.54%。

(4) 本文在单阶段目标检测算法基础上,建立了一个轻量级的图像分割分支,实现了裂缝图像实时分类、检测及分割多任务一体化集成目标,结果表明该算法能够正确分类裂缝图像,裂缝检测的精确度和 mAP@0.5 分别能达到 82.22% 和 83.32%,裂缝分割的平均交并比达到 94.63%,两者的推理时间均在毫秒量级,可以实现搭载移动设备进行桥梁裂缝实时分类、检测及分割多任务的目标。

(5) 本文提出了一种基于裂缝像素所在行或列的模型推理结果精细化评估方法,能够依据图像分割效果精细化定量评价模型的推理效果。裂缝图像实例推理结果表明基于裂缝像素所在行或列的精细化评估方法不仅可以得到量化的模型推理效果,而且还能直观地获取泛化能力相对差的部位,如裂缝形状突变部位。

(6) 结合有限单元法的基本思想,提出了一种基于微元法的裂缝参数计算方法。该方法避免了采用传统骨架线等提取算法带来的误差,实现了亚像素级计算精度,并且形成了一套集裂缝分布、宽度、长度、角度及间距等参数于一体的计算方法。与实测的裂缝宽度比较,本文提出的裂缝宽度计算方法相对误差在 7% 以下。

(7) 本文提出了一种由改进的单阶段裂缝实时目标检测算法和裂缝扩展基准方法组成的裂缝动态扩展监测方法,该方法不仅可以对桥梁混凝土结构产生的裂缝进行实时识别,而且还能高效、精准地全时域动态追踪裂缝扩展,尤其是细小裂缝也能很好的被监测到,该方法的可行性和有效性得到了验证。

基于视觉的混凝土裂缝识别与监测研究正处于

发展阶段,如何在全域内实现桥梁结构表观缺陷和损伤的多目标多任务一体化实时检测和量化分析,同时实现一感多识和一模多识的目标是后续研究的重点。

参考文献:

References:

- [1] 岳清瑞,刘晓刚,陈洪兵. 结构服役安全智能诊断研究与应用进展[J]. 建筑结构学报, 2022, 43(10): 41-49.
YUE Qing-rui, LIU Xiao-gang, CHEN Hong-bing. Research and application progress of intelligent diagnosis for structural service safety [J]. Journal of Building Structures, 2022, 43 (10): 41-49.
- [2] 刘宇飞,樊健生,聂建国,等. 结构表面裂缝数字图像法识别研究综述与前景展望[J]. 土木工程学报, 2021, 54(6): 79-98.
LIU Yu-fei, FAN Jian-sheng, NIE Jian-guo, et al. Review and prospect of digital-image-based crack detection of structure surface [J]. China Civil Engineering Journal, 2021, 54 (6): 79-98.
- [3] LIU Y F, NIE X, FAN J S, et al. Image-based crack assessment of bridge piers using unmanned aerial vehicles and three-dimensional scene reconstruction [J]. Computer-aided Civil and Infrastructure Engineering, 2020, 35 (5): 511-529.
- [4] JANG K, AN Y K, KIM B, et al. Automated crack evaluation of a high-rise bridge pier using a ring-type climbing robot [J]. Computer-aided Civil and Infrastructure Engineering, 2021, 36 (1): 14-29.
- [5] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks [J]. Communications of the ACM, 2017, 60 (6): 84-90.
- [6] SZEGEDY C, LIU W, JIA Y Q, et al. Going deeper with convolutions [C] // IEEE. 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2015: 1-9.
- [7] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition [EB/OL]. (2014-09-04) [2023-03-10]. <https://arxiv.org/abs/1409.1556>. pdf.
- [8] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition [C] // IEEE. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2016: 770-778.
- [9] JOCHER G. YOLOv5 (2022) [EB/OL]. [2023-03-10]. <https://github.com/ultralytics/yolov5>.
- [10] LI C Y, LI L L, JIANG H L, et al. YOLOv6: A single-stage object detection framework for industrial applications [EB/OL]. (2022-09-07) [2023-03-10]. <https://arxiv.org/abs/2209.02976>. pdf.
- [11] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [EB/OL]. (2022-07-06) [2023-03-10]. <https://arxiv.org/abs/2207.02696>. pdf.
- [12] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot multibox detector [C] // Springer. European Conference on Computer Vision. Cham: Springer, 2016: 21-37.
- [13] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42 (2): 318-327.
- [14] GIRSHICK R. Fast R-CNN [C] // IEEE. 2015 IEEE International Conference on Computer Vision (ICCV). New York: IEEE, 2015: 1440-1448.
- [15] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39 (6): 1137-1149.
- [16] HE K M, ZHANG X Y, REN S Q, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37 (9): 1904-1916.
- [17] NAYYERI F, HOU L, ZHOU J, et al. Foreground - background separation technique for crack detection [J]. Computer-aided Civil and Infrastructure Engineering, 2019, 34 (6): 457-470.
- [18] KONG S Y, FAN J S, LIU Y F, et al. Automated crack assessment and quantitative growth monitoring [J]. Computer-aided Civil and Infrastructure Engineering, 2021, 36 (5): 656-674.
- [19] XIE X Y, CAI J L, WANG H Z, et al. Sparse-sensing and superpixel-based segmentation model for concrete cracks [J]. Computer-aided Civil and Infrastructure Engineering, 2022, 37 (13): 1769-1784.
- [20] HANG J Q, WU Y J, LI Y C, et al. A deep learning semantic segmentation network with attention mechanism for concrete crack detection [J]. Structural Health Monitoring, 2023, 22 (5): 3006-3026.
- [21] SHELHAMER E, LONG J, DARRELL T. Fully convolutional networks for semantic segmentation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39 (4): 640-651.
- [22] CHEN L C, PAPANDREOU G, SCHROFF F, et al. Rethinking atrous convolution for semantic image segmentation [EB/OL]. (2017-06-17) [2023-03-10]. <https://arxiv.org/abs/1706.05587>. pdf.
- [23] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation [C] // Springer. Lecture Notes in Computer Science. Cham: Springer International Publishing, 2015: 234-241.
- [24] HE K M, GKIOXARI G, DOLLAR P, et al. Mask R-CNN [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42 (2): 386-397.
- [25] YU C Q, WANG J B, PENG C, et al. BiSeNet: Bilateral segmentation network for real-time semantic segmentation [C] // Springer. Computer Vision-ECCV 2018. Cham: Springer International Publishing, 2018: 334-349.
- [26] ZHAO H S, SHI J P, QI X J, et al. Pyramid scene parsing network [C] // IEEE. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE,

- 2017; 6230-6239.
- [27] BADRINARAYANAN V, KENDALL A, CIPOLLA R. SegNet: A deep convolutional encoder-decoder architecture for image segmentation [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 39 (12): 2481-2495.
- [28] LIN G S, MILAN A, SHEN C H, et al. RefineNet: Multi-path refinement networks for high-resolution semantic segmentation [C] // IEEE. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017: 5168-5177.
- [29] ZHENG Y E, GAO Y Q, LU S Y, et al. Multistage semisupervised active learning framework for crack identification, segmentation, and measurement of bridges [J]. *Computer-Aided Civil and Infrastructure Engineering*, 2022, 37 (9): 1089-1108.
- [30] MENG S Q, GAO Z Y, ZHOU Y, et al. Real-time automatic crack detection method based on drone [J]. *Computer-aided Civil and Infrastructure Engineering*, 2023, 38 (7): 849-872.
- [31] LIN Y B, CHANG K C, CHERN J C, et al. The health monitoring of a prestressed concrete beam by using fiber Bragg grating sensors [J]. *Smart Materials and Structures*, 2004, 13 (4): 712-718.
- [32] BERROCAL C G, FERNANDEZ I, REMPLING R. Crack monitoring in reinforced concrete beams by distributed optical fiber sensors [J]. *Structure and Infrastructure Engineering*, 2021, 17 (1): 124-139.
- [33] LAW T H, GUO B H. *Frontier research: Road and traffic engineering* [M]. London: CRC Press, 2022.
- [34] WEI H, HU B, WANG F Y, et al. Temporal-spatial evolution characteristics of acoustic emission in asphalt concrete cracking process under low temperature [J]. *Construction and Building Materials*, 2020, 248: 118632.
- [35] NISHIYAMA S, MINAKATA N, KIKUCHI T, et al. Improved digital photogrammetry technique for crack monitoring [J]. *Advanced Engineering Informatics*, 2015, 29 (4): 851-858.
- [36] MAEDA H, SEKIMOTO Y, SETO T, et al. Road damage detection and classification using deep neural networks with smartphone images [J]. *Computer-aided Civil and Infrastructure Engineering*, 2018, 33 (12): 1127-1141.
- [37] LIU Y H, YAO J, LU X H, et al. DeepCrack: A deep hierarchical feature learning architecture for crack segmentation [J]. *Neurocomputing*, 2019, 338: 139-153.
- [38] YANG X C, LI H, YU Y T, et al. Automatic pixel-level crack detection and measurement using fully convolutional network [J]. *Computer-aided Civil and Infrastructure Engineering*, 2018, 33 (12): 1090-1109.
- [39] LI S Y, ZHAO X F, ZHOU G Y. Automatic pixel-level multiple damage detection of concrete structure using fully convolutional network [J]. *Computer-aided Civil and Infrastructure Engineering*, 2019, 34 (7): 616-634.
- [40] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition [C] // IEEE. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2016: 770-778.
- [41] YU F, KOLTUN V, FUNKHOUSER T. Dilated residual networks [C] // IEEE. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017: 636-644.
- [42] CHOLLET F. Xception: Deep learning with depthwise separable convolutions [C] // IEEE. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017: 1800-1807.
- [43] SANDLER M, HOWARD A, ZHU M L, et al. MobileNetV2: Inverted residuals and linear bottlenecks [C] // IEEE. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE, 2018: 4510-4520.
- [44] LIU Y C, SHAO Z R, HOFFMANN N. Global attention mechanism: Retain information to enhance channel-spatial interactions [EB/OL]. (2021-12-10) [2023-03-10]. <https://arxiv.org/abs/2112.05561>. pdf.
- [45] LIU Z, LIN Y T, CAO Y E, et al. Swin transformer: Hierarchical vision transformer using shifted windows [C] // IEEE. 2021 IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2021: 9992-10002.
- [46] XIE E Z, WANG W H, YU Z D, et al. SegFormer: Simple and efficient design for semantic segmentation with transformers [J]. *Advances in Neural Information Processing Systems*, 2021, 34: 12077-12090.
- [47] PAYAB M, ABBASINA R, KHANZADI M. A brief review and a new graph-based image analysis for concrete crack quantification [J]. *Archives of Computational Methods in Engineering*, 2019, 26 (2): 347-365.
- [48] NI F T, ZHANG J A, CHEN Z Q. Zernike-moment measurement of thin-crack width in images enabled by dual-scale deep learning [J]. *Computer-aided Civil and Infrastructure Engineering*, 2019, 34 (5): 367-384.
- [49] SHAN B H, ZHENG S J, OU J P. A stereovision-based crack width detection approach for concrete surface assessment [J]. *KSCE Journal of Civil Engineering*, 2016, 20 (2): 803-812.
- [50] ADHIKARI R S, MOSELHI O, BAGCHI A. Image-based retrieval of concrete crack properties for bridge inspection [J]. *Automation in Construction*, 2014, 39: 180-194.
- [51] LU C, YU J, LEUNG C K Y. An improved image processing method for assessing multiple cracking development in Strain Hardening Cementitious Composites (SHCC) [J]. *Cement and Concrete Composites*, 2016, 74: 191-200.
- [52] IYER S, SINHA S K. Segmentation of pipe images for crack detection in buried sewers [J]. *Computer-Aided Civil and Infrastructure Engineering*, 2006, 21 (6): 395-410.
- [53] SAEED K, TAB D Z K I, RYBNIK M, et al. K3M: A universal algorithm for image skeletonization and a review of thinning techniques [J]. *International Journal of Applied Mathematics and Computer Science*, 2010, 20 (2): 317-335.